Estadística Descriptiva

Cotos-Yáñez, T.R., Pérez-González, A.

2024-09-19

Contents

Prólogo **5**

1 Introducción. Elementos notables de Estadística Descriptiva **7**
1.1 Introducción 7
1.2 Conceptos Generales. 8

2 Estadística Descriptiva Unidimensional **11**
2.1 Tablas de distribución de frecuencias: 12
2.2 Representaciones Gráficas 18
2.3 Principales características numéricas 30

Prólogo

Esta documentación contiene tanto la parte Teórica de la materia como su aplicación práctica usando el lenguaje R a través del plugin R-Commander y el plugin RcomanderPlugin.InferenciaEstadistica.

Está escrito en R-Markdown empleando el paquete `bookdown` y está disponible en el repositorio Github: ¿?¿?.

Este obra está bajo licencia de Creative Commons Reconocimiento-NoComercial-SinObraDerivada 4.0 Internacional.

Chapter 1

Introducción. Elementos notables de Estadística Descriptiva

1.1 Introducción

Un primer paso en cualquier análisis de un problema o experimento es la observación de la información disponible. Esta información debe ser tratada inicialmente como un todo y es conveniente establecer mecanismos que permitan, no solo describirla completamente, sino también resumirla. Dicho de otra forma, dar características que permitan describir la información que se dispone. La estadística descriptiva es la parte de la estadística que se encarga de ordenar, analizar, representar y resumir un conjunto de datos, tratándolos como un todo.

Un claro ejemplo pueden ser los análisis descriptivos que se hacen de las visitas a portales web (buscar en google *estadística web* y pinchar por ejemplo en *Imagenes de estadística web*).

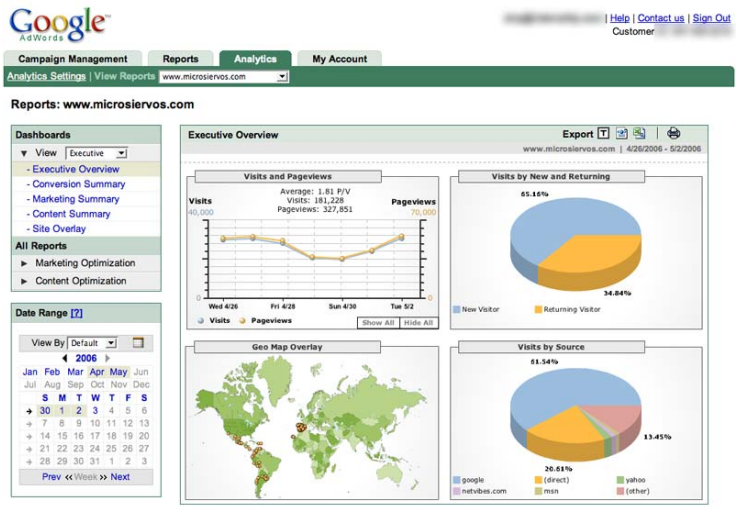

1.2 Conceptos Generales.

- **Población**. Cualquier conjunto de personas, objetos, ideas o acontecimientos.

- **Muestra**. Subconjunto de individuos pertenecientes a una población determinada. Es deseable que sea un subconjunto *representativo* de la población.

- **Variables**: En los elementos de una población se pueden observar uno o varios caracteres:

  – *Variable cualitativa o atributo*: Es un carácter de una población que no es susceptible de ser medido numéricamente. Se clasifican en nominales y ordinales. La v. cualitativas ordinales se pueden ordenar.

  Ejemplos de variables cualitativas nominales son: el color de ojos, la raza, el sexo, la inclinación política, . . . , ejemplos de v. ordinales son: el nivel de estudios, la escala de grises (de blanco a negro), grado de escolaridad, etapa en el desarrollo humano, grados entre totalmente en desacuerdo hasta el totalmente de acuerdo. . .

  – *Variable cuantitativa*: Es cualquier carácter de una población susceptible de tomar valores numéricos. Se clasifican en discretas y continuas. Mientras que las discretas toman únicamente un número finito o infinito numerable de valores, las continuas pueden tomar todos los valores de un determinado intervalo.

  Ejemplos de variables discretas: número de trabajos en cola en un servidor, número de hijos, número de caras obtenidas al lanzar dos monedas, . . .

Ejemplos de variables continuas: salario, peso, estatura, ...

Ejercicio 1.1. Identifica que tipo de variables son:

```
- tipo de procesador,

- velocidad de un procesador (MHz),

- modelo de impresora,

- número de páginas impresas por minuto,

- variable representando un byte,

- la altura y el peso de una persona,

- la parte entera de la medición de la altura de una persona,

- ¿la variable número de núcleos de un procesador es ordinal o cuantitativa discreta?

- Describe situaciones donde la variable *Edad* pueda ser considerada como v.a. continua, discret
```

Chapter 2

Estadística Descriptiva Unidimensional

Sea X la variable de interés, y sean $x_1, x_2, \ldots, x_k$ los valores distintos que toma dicha variable medidos en una muestra de tamaño N.

- **Frecuencia absoluta**: número de veces que se repite cada valor de la variable.
- **Frecuencia relativa**: frecuencia absoluta dividida por el número total de datos, N.
- **Frecuencia absoluta acumulada** de un valor de la variable (ordenados de menor a mayor) es el número de datos menores o iguales que dicho valor (no calculable para v. cualitativas nominales).
- **Frecuencia relativa acumulada** es el resultado de dividir cada frecuencia absoluta acumulada por el número total de datos.

Fr. Absoluta de x_i n_i	**Fr. Relativa de x_i** f_i
Fr. Abs. Acumulada de x_i $N_i = n_1 + \ldots + n_i = \sum_{k=1}^{i} n_k$	**Fr. Rel. Acumulada de x_i** $F_i = f_1 + \ldots + f_i = \sum_{k=1}^{i} f_k = \frac{N_i}{N}$

2.1 Tablas de distribución de frecuencias:

- **Variables cualitativas y cuantitativas discretas**: Datos sin agrupar.

Valores variable	Fr. abs.	Fr. rel.	Fr. abs. ac.	Fr. rel. ac.
x_i	n_i	$f_i = \frac{n_i}{N}$	$N_i = \sum_{j=1}^{i} n_j$	$F_i = \frac{N_i}{N}$
x_1	n_1	f_1	N_1	F_1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_k	n_k	f_k	$N_k = N$	$F_k = 1$
	$N = \sum_{i=1}^{k} n_i$	1		

Las frecuencias acumuladas sólamente tienen sentido cuando hay una ordenación de los datos, es decir, no tienen sentido cuando hay variables cualitativas nominales.

Ejemplo

Variable cualitativa nominal:

```
> data(iris)
> calcular_frecuencia(df.nominal=iris["Species"], ordenado.frec=FALSE, df.ordinal=NULL
```

```
-------------------------------

Variábeis nominais:

Variábel: Species
           ni    fi
setosa     50 0.333
versicolor 50 0.333
virginica  50 0.333
N= 150
```

Variable cualitativa ordinal: Del paquete *cars93* consideremos la variable *Airbags* en función de la seguridad del coche, entonces:

```
> data(car93)
> cars93 <- within(cars93, {
+   Airbags <- factor(Airbags, levels=c('none','driver','driver&passenger'), ordered=TR
+ })
> calcular_frecuencia(df.nominal=NULL, ordenado.frec=FALSE, df.ordinal=cars93["Airbags"
```

```
-------------------------------

Variábeis ordinais:
```

```
Variábel: Airbags
                 ni    fi Ni    Fi
none             34 0.366 34 0.366
driver           43 0.462 77 0.828
driver&passenger 16 0.172 93 1.000
N= 93

Cuantile: 0.5
        Variable       Fi
Airbags   driver 0.827957
```

Variable cualitativa discreta: Número de cilindros

```
> calcularResumenVariablesDiscretas(data=cars93["Cylinders"], statistics =c("mean", "sd", "IQR",
+   groups=NULL, tablaFrecuencia=TRUE, cortes=NULL)


-------------------------------

Resumos numéricos:
     mean       sd IQR 0% 25% 50% 75% 100%  n NA
 4.967391 1.304692   2  3   4   4   6    8 92  1

-------------------------------

Distribución de frecuencias para variábeis discretas:

Variábel: Cylinders
  ni     fi Ni     Fi
3  3 0.0326  3 0.0326
4 49 0.5326 52 0.5652
5  2 0.0217 54 0.5870
6 31 0.3370 85 0.9239
8  7 0.0761 92 1.0000
N= 92
```

- **Variables cuantitativas continuas**: Datos agrupados.

Si el tamaño N de la muestra es grande, suelen agruparse los datos en casillas o intervalos de clase de la forma $[L_{i-1}, L_i)$ donde $i = 1, 2, \ldots, k$,sustituyendo cada valor de la variable por el punto medio del intervalo $x_i = \dfrac{L_{i-1} + L_i}{2}$ que llamaremos **marca de clase**.

Int. clase	**M. clase**	**Fr. abs.**	**Fr. rel.**	**Fr. abs. ac.**	**Fr. rel. ac.**	**Amp.**	**Densidad**
$[L_{i-1}, L_i)$	x_i	n_i	f_i	N_i	F_i	a_i	d_i
$[L_0, L_1)$	x_1	n_1	f_1	N_1	F_1	a_1	d_1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$[L_{k-1}, L_k]$	x_k	n_k	f_k	$N_k = N$	$F_k = 1$	a_k	d_k
		N	1				

Se define **amplitud del intervalo** de clase como $a_i = L_i - L_{i-1}$. Los intervalos no tienen por qué tener la misma amplitud.

Se define **densidad de frecuencia** relativa como la frecuencia relativa por unidad de la variable, $d_i = \frac{f_i}{a_i}$.

Ejemplo

El conjunto de datos *iris* del paquete *datasets* (*Estadística Básica/Datos/Conjunto de datos en paquetes/Leer conjunto de datos en paquete adjunto...*) contiene mediciones en centímetros de diferentes variables de 150 flores (ver ayuda del conjunto de datos).

Responder a las siguientes cuestiones:

- Clasifica estadísticamente las variables del conjunto de datos *iris*.
- Calcula la distribución de frecuencias completa de la variable *Species*.
- Obtén la distribución de frecuencias agrupada de la variable *Sepal.Lenght* en 10 grupos de longitud 0.5.
- Obtén la distribución de frecuencias agrupada de la variable *Sepal.Lenght* en 8 grupos de longitud 0.5 empezando en 4.0, usando el menú Recodificar.

Solución:

```
> # Sepal.Length, Sepal.Width, Petal.Length, Petal.Width son v. continuas.
> # Species es una v. cualitativa nominal.
>
> ### Menú en: Estadística Básica/Estadística Descriptiva/Distribuciones de frecuencia
> ###   variables cualitativas
> calcular_frecuencia(df.nominal=iris["Species"], ordenado.frec=TRUE, df.ordinal=NULL,
+   cuantil.p=0.5, iprint = TRUE)
```

```
-------------------------------

Variábeis nominais:

Variábel: Species
           ni    fi
setosa     50 0.333
versicolor 50 0.333
virginica  50 0.333
N= 150
```

```
> ###  Menú en: Estadística Básica/Estadística Descriptiva/Resúmenes numéricos
> ###  Seleccionar la variable y marcar Tabla de frecuencias y 10 cortes
> calcularResumenVariablesContinuas(data=iris["Petal.Length"],
+   statistics=c("mean", "sd", "IQR", "quantiles"), quantiles=c(0,0.25,0.5,0.75,1),
+   tablaFrecuencia=TRUE, cortes=10)
```

```
-------------------------------

Resumos numéricos:
  mean       sd IQR 0% 25%  50% 75% 100%   n
 3.758 1.765298 3.5  1 1.6 4.35 5.1  6.9 150

-------------------------------

Distribución de frecuencias para variábeis continuas:

Variábel: Petal.Length
              Li_1   Li   xi ni     fi  Ni    Fi    ai     hi
[0.994,1.59) 0.994 1.59 1.29 37 0.2467  37 0.247 0.596 0.4139
[1.59,2.18)  1.590 2.18 1.89 13 0.0867  50 0.333 0.590 0.1469
[2.18,2.77)  2.180 2.77 2.48  0 0.0000  50 0.333 0.590 0.0000
[2.77,3.36)  2.770 3.36 3.06  3 0.0200  53 0.353 0.590 0.0339
[3.36,3.95)  3.360 3.95 3.66  8 0.0533  61 0.407 0.590 0.0904
[3.95,4.54)  3.950 4.54 4.25 26 0.1733  87 0.580 0.590 0.2938
[4.54,5.13)  4.540 5.13 4.83 29 0.1933 116 0.773 0.590 0.3277
[5.13,5.72)  5.130 5.72 5.42 18 0.1200 134 0.893 0.590 0.2034
[5.72,6.31)  5.720 6.31 6.01 11 0.0733 145 0.967 0.590 0.1243
[6.31,6.91]  6.310 6.91 6.61  5 0.0333 150 1.000 0.600 0.0556
N= 150
```

```
> ### Proceso: Recodificar + Transformar a Tipo factor ordenado + obtener la tabla
>
> ### Primero: Recodificamos la variable usando el menú de segmentar
> ###   Estadística Básica/Datos/Segmentar variable numérica
```

```
> iris$Sepal.Length.agrup2 <- as.ordered(with(iris, binVariable(Sepal.Length, bins=8,
+       method='intervals', labels=NULL)))
>
> ### Segundo: La v. generada es una v.a continua agrupada, para obtener la distribuci
> ###   de frecuencias completa, podemos usar el menú de distribución de frecuencias d
> ###   v. cualitativas ordinales. Informáticamente el menú anterior clasificó la v.
> ###   resultante como v. tipo factor ordenado.
>
> ### Menú: Distribución de frecuencias de v. cualitativas ordinales,
> ###   Estadística Básica/Estadística Descriptiva/Distribuciones de frecuencia variabl
> ###   cualitativas...
> calcular_frecuencia(df.nominal=NULL, ordenado.frec=FALSE, df.ordinal=
+       iris["Sepal.Length.agrup2"], cuantil.p=0.5, iprint = TRUE)


--------------------------------

Variábeis ordinais:

Variábel: Sepal.Length.agrup2
           ni     fi  Ni     Fi
(4.3,4.75] 11 0.0733  11 0.0733
(4.75,5.2] 34 0.2267  45 0.3000
(5.2,5.65] 20 0.1333  65 0.4333
(5.65,6.1] 30 0.2000  95 0.6333
(6.1,6.55] 25 0.1667 120 0.8000
(6.55,7]   18 0.1200 138 0.9200
(7,7.45]    6 0.0400 144 0.9600
(7.45,7.9]  6 0.0400 150 1.0000
N= 150

Cuantile: 0.5
                      Variable        Fi
Sepal.Length.agrup2 (5.65,6.1] 0.6333333
> ### La densidad de frecuncia se obtendría dividiendo la columna fi por la amplitud.
> ###   En este caso, amplitud constante ai=0.5. Las conclusiones serían idénticas
> ###   observando la columna hi e fi.
>
>
> ### Usando el menú de Recodificar,
> ### Primero: Recodificamos en Estadística Básica/Datos/Modificar el conjunto de dato
> ###   activo/Recodificar ...
> iris <- within(iris, {
+   Sepal.Length.agrup2 <- Recode(Sepal.Length,
+   '4:4.5 = "[4,4.5]"; 4.5:5 = "(4.5,5]"; 5:5.5 = "(5,5.5]"; 5.5:6 = "(5.5,6]";
```

```
+   6:6.5 = "(6,6.5]"; 6.5:7 = "(6.5,7]"; 7:7.5 = "(7,7.5]"; 7.5:8 = "(7.5,8]"',
+   as.factor=TRUE)
+ })
> ### Segundo: La v. generada es una v.a continua agrupada, para obtener la
> ###   distribución de frecuencias completa, podemos usar el menú de distribución
> ###   de frecuencias de v. cualitativas ordinales. Informáticamente el menú
> ###   anterior clasificó la v. resultante como v. tipo factor (es decir, v.
> ###   cualitativa nominal). Debemos modificar para que se R Commander la
> ###   considere como factor ordenado.
>    ### Menú: Estadística Básica/Datos/Modificar el conjunto de datos activo
> ###   /Cambiar tipo de variables
> iris <- within(iris, {
+   Sepal.Length.agrup2 <- as.ordered(Sepal.Length.agrup2)
+ })
> ###  Reordenar los niveles de factor dado que [4,4.5] aparece en la última posición
> iris <- within(iris, {
+   Sepal.Length.agrup2 <- factor(Sepal.Length.agrup2, levels=c('[4,4.5]',
+   '(4.5,5]','(5,5.5]','(5.5,6]','(6,6.5]','(6.5,7]','(7,7.5]','(7.5,8]'),
+   ordered=TRUE)
+ })
> ### Tercero: Distribución de frecuencias de v. cualitativas ordinales,
> ###   Estadística Básica/Estadística Descriptiva/Distribuciones de frecuencia
> ###    variables cualitativas...
> calcular_frecuencia(df.nominal=NULL, ordenado.frec=FALSE, df.ordinal=
+       iris["Sepal.Length.agrup2"], cuantil.p=0.5, iprint = TRUE)
```

```
--------------------------------

Variábeis ordinais:

Variábel: Sepal.Length.agrup2
        ni     fi  Ni     Fi
[4,4.5]  5 0.0333   5 0.0333
(4.5,5] 27 0.1800  32 0.2133
(5,5.5] 27 0.1800  59 0.3933
(5.5,6] 30 0.2000  89 0.5933
(6,6.5] 31 0.2067 120 0.8000
(6.5,7] 18 0.1200 138 0.9200
(7,7.5]  6 0.0400 144 0.9600
(7.5,8]  6 0.0400 150 1.0000
N= 150

Cuantile: 0.5
                    Variable        Fi
```

```
Sepal.Length.agrup2  (5.5,6] 0.5933333
```

Ejercicio 2.1. La distribución del tiempo de conexión a la red internet en un edificio viene agrupado en intervalos por la siguiente tabla:

Tiempo (minutos)	Marca Clase	Nº de usuarios
$(0-20]$	10	10
$(20-28]$	24	32
$(28-32]$	30	50
$(32-48]$	40	8

Obtén la distribución de frecuencias completa de la variable agrupada.

Solución. La variable estadística a considerar se puede definir como X=*tiempo de conexión*, la tabla completa quedaría:

Tiempo (minutos)	Marca Clase	Nº de usuarios	N_i	f_i	F_i	d_i
$(0-20]$	10	10	10	10/100	10/100	$\frac{0.1}{20}=0.005$
$(20-28]$	24	32	42	32/100	42/100	$\frac{0.32}{8}=0.04$
$(28-32]$	30	50	92	50/100	92/100	$\frac{0.5}{4}=0.125$
$(32-48]$	40	8	100	8/100	100/100	$\frac{0.08}{16}=0.005$

2.2 Representaciones Gráficas

Aunque la tabla estadística encierra toda la información posible disponible, a veces es necesario traducirla o acompañarla de una representación gráfica de modo que la referencia visual sirva de punto de partida para el análisis estadístico. Los tipos de gráficos más utilizados son:

1. Para fenómenos cualitativos: cartograma, pictograma, nube de palabras, diagrama de sectores y diagrama de rectángulos.
2. Para fenómenos cuantitativos:
   - Distribuciones no agrupadas: diagrama de barras y polígono de frecuencias.
   - Distribuciones agrupadas: histograma de frecuencias, polígono de frecuencias y polígono acumulativo.

2.2.1 En distribuciones cualitativas.

Pictogramas: Los datos se representan gráficamente sustituyendo las barras del diagrama de barras o los rectángulos del histograma por figuras alusivas al carácter estudiado.

Cartogramas: Es la forma de representar sobre el mapa de la región estudiada los caracteres correspondientes, bien empleando distintos colores, tramas de distinta intensidad, o con una numeración adecuada.

Diagramas sectoriales: Consiste en representar mediante sectores circulares las distintas modalidades de la variable de manera que los sectores han de tener un ángulo central proporcional a la frecuencia correspondiente.

Diagrama de rectángulos: Todos los rectángulos tienen la misma base y sus áreas son proporcionales a la frecuencia.

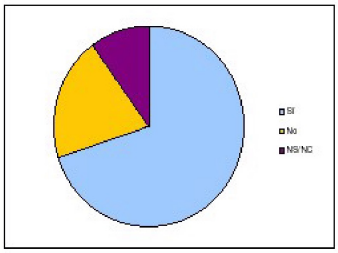

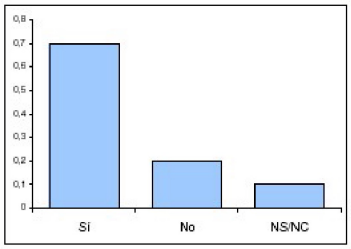

Nube de palabras: En textos, cuando hay muchas palabras:

```
> library(tm)
> library(wordcloud)
> library(colorspace, pos=18)
>
> apelidos.nomes <- read.csv("data/2020-2021estudantes ESEI.csv", header=FALSE)
>   apelidos.nomes <- unique(apelidos.nomes) # Elimino entradas duplicadas
>   apelidos <- unlist(strsplit(as.character(apelidos.nomes$V1), split=" "))
>   nomes <- apelidos.nomes$V2
>   freq <- table(nomes)
>   freq1 <- freq[order(freq,decreasing = TRUE)][1:35]
>   wordcloud(attr(freq1,"dimnames")[[1]],freq=freq1, colors=rainbow(length(freq1)))
```

```
> data(iris, package="datasets")
> ### Representa gráficamente la v. cualitativa nominal Species.
> ### Con R Commander.  Menú Gráficas/Diagrama de barras
> with(iris, Barplot(Species, main="Frecuencias absolutas", ylab="Frequency"))
```

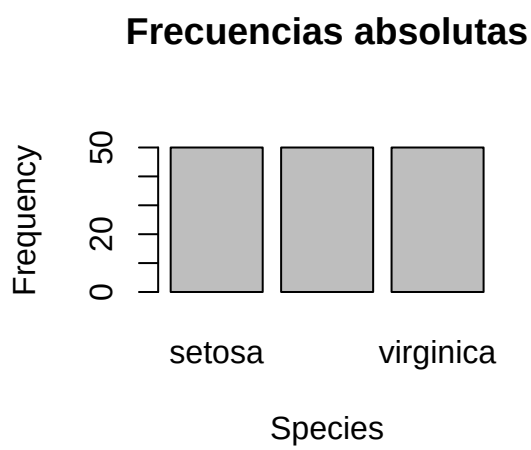


```
> with(iris, Barplot(Species, main="Porcentajes", ylab="Percent", scale="percent"))
```

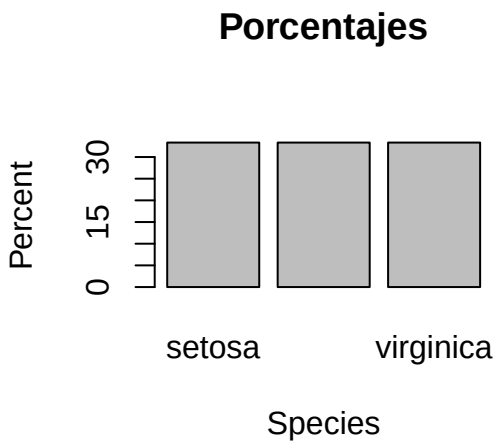


```
> ### Con R Commander.  Menú Gráficas/Diagrama de sectores
> with(iris, pie(table(Species), labels=levels(Species), xlab="", ylab="",
+     main="Species", col=rainbow_hcl(3)))
```

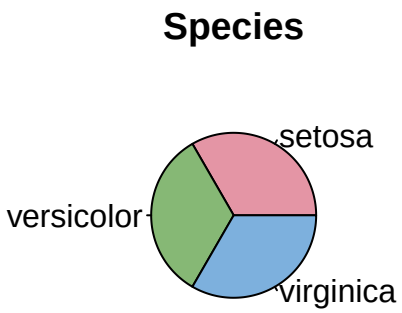

2.2.2 En distribuciones cuantitativas discretas no agrupadas.

Diagrama de barras: En el eje de abscisas, de unos ejes coordenados rectangulares, se señalan los valores de la variable, construyendo sobre estos unos segmentos verticales de longitud igual (o proporcional) a cada una de las frecuencias.

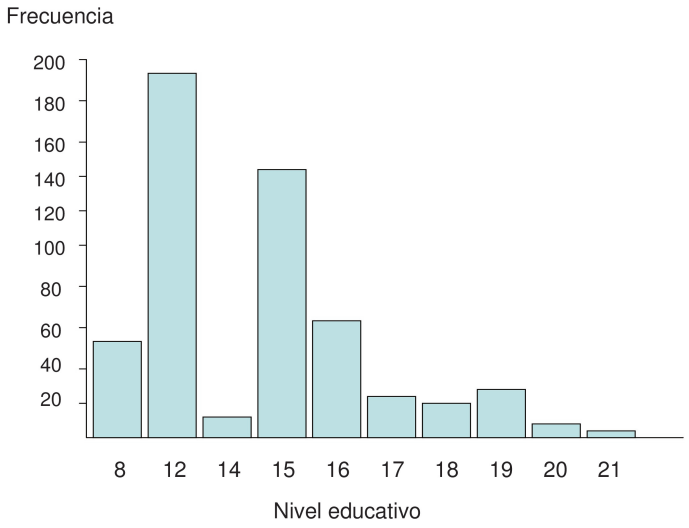

Polígono de frecuencias: Se obtiene uniendo mediante segmentos los puntos $(x_1, n_1), (x_2, n_2), \ldots, (x_k, n_k)$ ó $(x_1, f_1), (x_2, f_2), \ldots, (x_k, f_k)$.

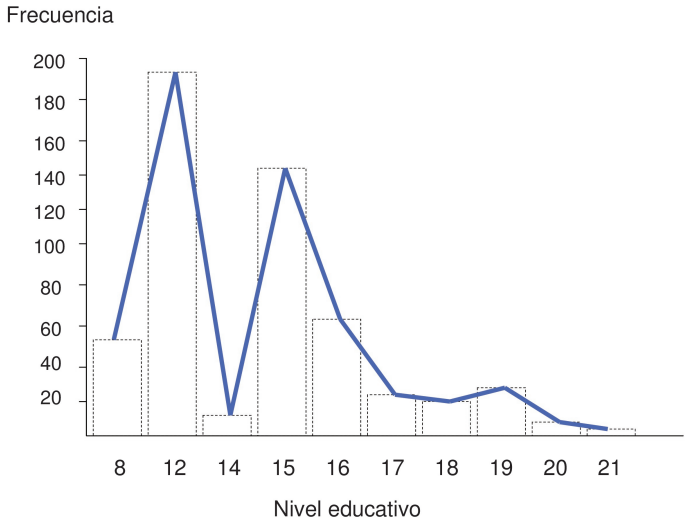

2.2.3 En distribuciones cuantitativas agrupadas en intervalos.

Histogramas: Se marcan en el eje X los extremos de los intervalos de clase, y sobre cada intervalo se construye un rectángulo cuya base coincide con el intervalo y la altura es igual (o proporcional) a la frecuencia de dicho intervalo. Generalmente $d_i = \dfrac{n_i}{a_i}$ ó $d_i = \dfrac{f_i}{a_i}$.

Pasos en la construcción de un histograma:

1. Determinar el rango de los datos. Rango es igual al dato mayor menos el dato menor.
2. Obtener el número de clases:

Regla de la raíz :	$k = int\left(\sqrt{N}\right)$
Regla de Sturgess :	$h = int\left(1 + log_2(N)\right)$ y $k = \frac{max(x)-min(x)}{h}$
Regla de Scott :	$h = 3.49\frac{S}{\sqrt[3]{N}}$, con S la desviación típica de los datos y $k = \frac{max(x)-min(x)}{h}$
Regla de Freedman-Diaconis :	$k = 2\frac{RIQ}{\sqrt[3]{N}}$

Suposiciones para la regla de Scott: asintóticamente cierta, el exponente -1/3 es para funciones suaves y el coeficiente 3.49 se obtiene suponiendo función de densidad gaussiana.

3. Establecer la longitud de clase: es igual al rango entre el número de clases.
4. Construir los intervalos de clases: Los intervalos resultan de dividir el rango de los datos en relación al resultado del PASO 2 en intervalos iguales. Obtener la frecuencia de datos dentro de cada intervalo.
5. Dibujar el histograma: En caso de que las clases sean todas de la misma amplitud, se hace un gráfico de barras unidas, las bases de las barras son los intervalos de clases y altura son la frecuencia (la relativa o la absoluta) de las clases. En caso de intervalos con longitudes desiguales la altura del intervalo es la densidad de frecuencia.

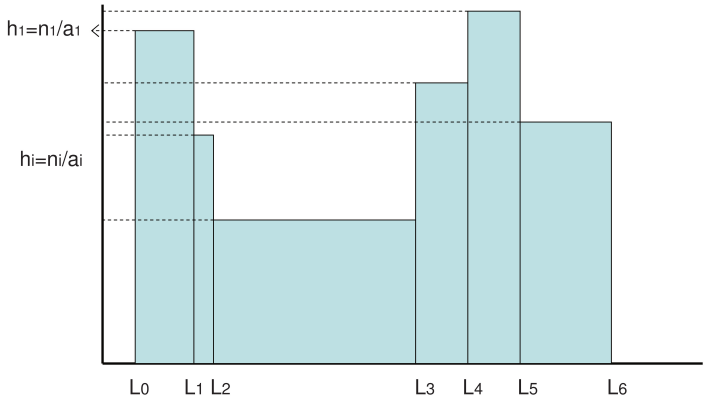

Polígono de frecuencias: Se obtiene al unir por segmentos los puntos medios de las bases superiores de los rectángulos del histograma.

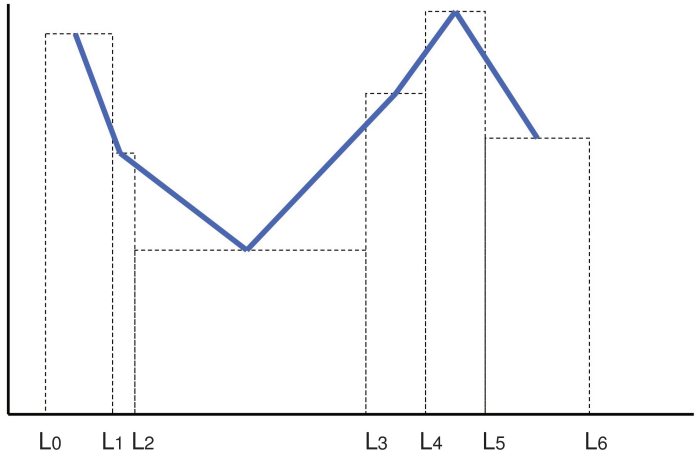

Ejemplo con R y R Commander: Representa gráficamente la v. continua Sepal.Length

```
> data(iris, package="datasets")
> ### Histogramas con R Commander.  Menú Gráficas/Histograma ...
> with(iris, Hist(Sepal.Length, scale="frequency", breaks="Sturges",
+     col="darkgray", main="Frecuencias absolutas"))
```

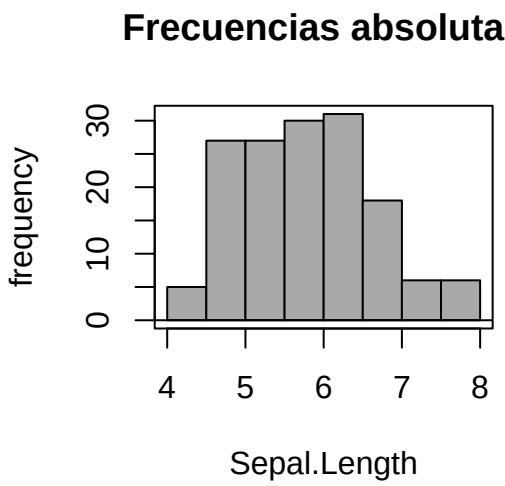


```
> with(iris, Hist(Sepal.Length, scale="percent", breaks="Sturges",
+     col="darkgray", main="Porcentajes"))
```

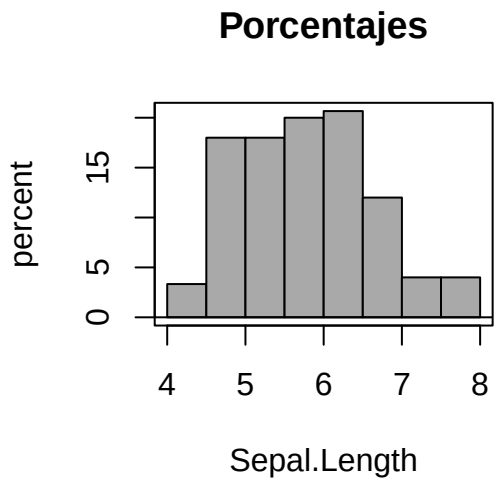


```
> with(iris, Hist(Sepal.Length, scale="density", breaks="Sturges",
+     col="darkgray", main="Densidad de frecuencia"))
```

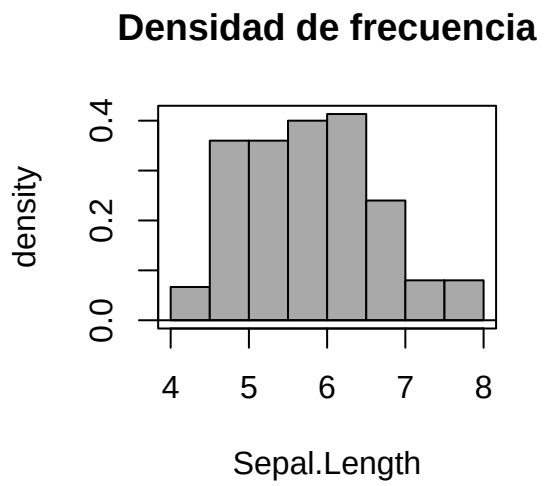


```
> ### Estimación no paramétrica de la densidad con R Commander.
> ###   Menú Gráficas/Estimar densidad
> densityPlot( ~ Sepal.Length, data=iris, bw=bw.SJ, adjust=1,
+              kernel=dnorm, method="adaptive")
```

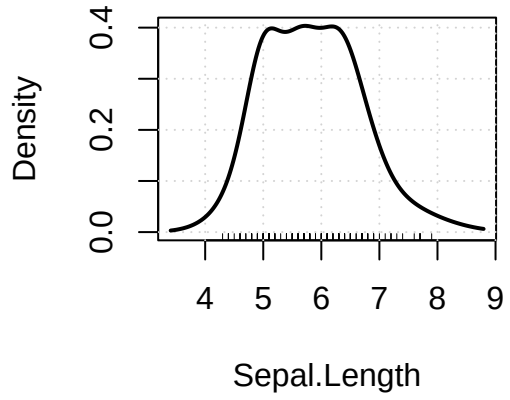


```
> ### Estimación no paramétrica de la densidad con R.
> hist(iris$Sepal.Length, main="Sepal.Length", xlab="", freq= FALSE)
> lines(density(iris$Sepal.Length), col="blue",lwd=2, lty=3)
```

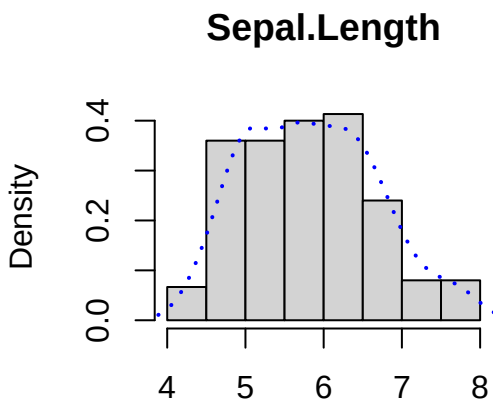

Ejercicio 2.2. Obervando los histogramas seguintes, en el eje de abcisas aparece el valor de la altura de cada barra, que porcentaje de flores tienen una longitud de Sepalo menor que 6.

```
> aa <- hist(iris$Sepal.Length, plot=FALSE)
> # con Freq. Absolutas
> hist(iris$Sepal.Length, col = "lightblue", main="", xlab="Frecuencia absoluta")
> text( aa$mids, aa$counts, labels=aa$counts, pos=1, cex=0.65)
```

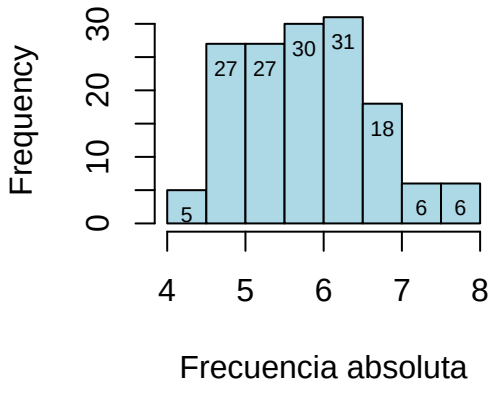

```
> # con densidad de frecuencias
> hist(iris$Sepal.Length, freq=FALSE, main="", col = "lightblue",
+      xlab="Densidad de frecuencia")
> text( aa$mids, aa$density, labels=round(aa$density,1), pos=1, cex=0.65)
```

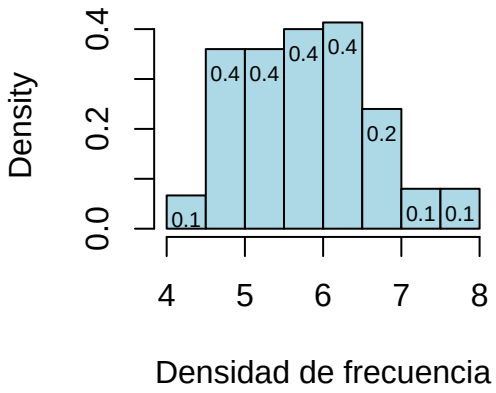

Ejercicio 2.3. Dado los valores recogidos en la tabla seguiente, calcula el área del recinto de cada uno de los gráficos anteriores.

Punto medio	4.25	4.75	5.25	5.75	6.25	6.75	7.25	7.75
n_i	5	27	27	30	31	18	6	6
d_i	0.0667	0.3600	0.3600	0.4000	0.4133	0.2400	0.0800	0.0800

Ejercicio 2.4. Completa con lapiz y papel las seguientes tablas de frecuencias, y comprueba que los resultados son correctos generando las tablas a partir del conjunto de datos *cars93* del plugin *RcmdrPlugin.TeachStat*. En los cálculos ten en cuenta el redondeo y usa (cuando haga falta) que N=93:

Cylinders	n_i	f_i	N_i	F_i
3	3	–	–	–
4	49	–	–	–
5	2	–	–	–
6	31	–	–	–
8	7	–	–	–

FuelCapacity	n_i	f_i	N_i	F_i
$[9.18, 12.8)$		0.12		
$[12.8, 16.3)$		0.38		
$[16.3, 19.9)$		0.31		
$[19.9, 23.4)$		0.18		
$[23.4, 27]$		0.01		

HighwayMPG	n_i	f_i	N_i	F_i
$[20, 26)$			22	
$[26, 32)$			71	
$[32, 38)$			88	
$[38, 44)$			91	
$[44, 50]$			93	

Horsepower	n_i	f_i	N_i	F_i
$[54.8, 104)$				0.26
$[104, 153)$				0.59
$[153, 202)$				0.88
$[202, 251)$				0.95
$[251, 300]$				1.00

2.3 Principales características numéricas

La información suministrada por una tabla de distribución de frecuencias se puede resumir en un conjunto de medidas que la caracterizan y que se pueden clasificar en:

1. Medidas de posición: proporcionan valores que determinan posiciones dentro del conjunto de los datos. Las dividimos en medidas de tendencia central y de tendencia no central.
2. Medidas de dispersión: indican la desviación de los datos respecto de ciertas medidas de posición.
3. Medidas de forma: relacionadas con la representación gráfica de la distribución.

2.3.1 Medidas de posición de tendencia central

Media aritmética ($\overline{x}$): cociente entre la suma de todos los valores observados de la variable y el número total de observaciones:

$$\overline{x} = \frac{\sum_{i=1}^{k} x_i n_i}{N}$$

Para datos agrupados se toman como x_i las marcas de clase (representante de todos los datos del intervalo).

Propiedades

1. $\sum_{i=1}^{k}(x_i - \overline{x})n_i = 0$.
2. La media de las desviaciones al cuadrado de los valores de las variable respecto a una constante c cualquiera, se hace mínima cuando esa constante c es igual a la media aritmética. Es decir:

$$\min_c \sum_{i=1}^{k}(x_i - c)^2 n_i = \sum_{i=1}^{k}(x_i - \overline{x})^2 n_i \text{ (Teorema de König)}$$

3. Linealidad de la media: dados $a, b \in \mathbb{R}$ e $Y = a + bX$ se verifica:

$$\overline{y} = a + b\overline{x}$$

4. Media en subpoblaciones: Si el total de datos se estratifica en L grupos distintos, la media aritmética del total es una media aritmé tica de las distintas medias de los estratos ponderadas por el número de observaciones que tienen los mismos:

$$\overline{x} = \frac{\overline{x}_1 N_1 + \overline{x}_2 N_2 + \ldots + \overline{x}_L N_L}{N_1 + N_2 + \ldots + N_L}$$

5. $\min(x_i) \leq \overline{x} \leq \max(x_i)$

NOTA: A veces se introducen unos coeficientes de ponderación o pesos denominados w_i que son distintos de n_i con lo que la +media ponderada+ es:

$$\overline{x}_w = \frac{\sum_{i=1}^{k} w_i x_i}{\sum_i w_i}$$

Ejemplo 2.1. Calcula la media aritmética de los 10 primeros números naturales. *X= 10 primeros números enteros.* $x_1 = 1, x_2 = 2, \ldots, x_{10} = 10$, frecuencias $n_i = 1$, $i = 1, 2, \ldots, 10$, por lo tanto $\bar{x} = \frac{1+2+\ldots+10}{10} = \frac{55}{10} = 5.5$

Ejemplo 2.2. Supón ahora que la ponderación de cada valor es inversamente proporcional a su valor. $x_1 = 1, x_2 = 2, \ldots, x_{10} = 10$, con pesos $w_i = \frac{1}{i}$, $i = 1, 2, \ldots, 10$, por lo tanto $\bar{x}_w = \frac{1*\frac{1}{1}+2*\frac{1}{2}+\ldots+10*\frac{1}{10}}{\frac{1}{1}+*\frac{1}{2}+\ldots+*\frac{1}{10}} = \frac{10}{2.928968} = 3.414172$

Ejemplo 2.3. Haz los cálculos anteriores con R-Commander generando una variable que tome valores de 1 al 10.

Media geométrica: la raíz N-ésima del producto de los N valores de la distribución elevados al número de veces que se repite cada uno de ellos:

$$g = \sqrt[N]{x_1^{n_1} x_2^{n_2} \ldots x_k^{n_k}}$$

Podemos expresar la media geométrica como una media aritmética teniendo en cuenta que el logaritmo de la media geométrica es igual a la media aritmética de los logaritmos de los valores de la variable:

$$\log(g) = \frac{\sum_{i=1}^{k} \log(x_i) n_i}{N}$$

El empleo más frecuente de la media geométrica es el de promediar porcentajes, tasas, números índices, etc.

Mediana (Me): dada una distribución de frecuencias $\{(x_i, n_i)\}_{i=1}^{k}$ con valores ordenados de menor a mayor, llamamos mediana, Me, al valor de la variable que deja a su izquierda la misma frecuencia que a su derecha. Es decir, serían el valor o valores de la variable que son mayores o iguales que la mitad de los datos y menore o iguales a la otra mitad de los datos.

Cálculo de la mediana:

1. Distribuciones no agrupadas: Se observa cuál es la primera frecuencia absoluta acumulada N_i que supera o iguala a $N/2$ distinguiéndose dos casos:

- Si $N_i > N/2$, entonces $Me = x_i$.
- Si $N_i = N/2$, entonces $Me = \dfrac{x_i + x_{i+1}}{2}$.

2. Distribuciones agrupadas: el cálculo se realiza en dos etapas:
   - Detectar el *intervalo mediano*: $[L_{i-1}, L_i)$ tal que $N_i \geq \dfrac{N}{2}$.
   - Cálculo de la mediana mediante semejanza de triángulos:

$$Me = L_{i-1} + \frac{\frac{N}{2} - N_{i-1}}{n_i} a_i = L_{i-1} + \frac{\frac{1}{2} - F_{i-1}}{f_i} a_i$$

siendo L_{i-1}: el extremo inferior del intervalo mediano.

N_{i-1}: la frecuencia absoluta acumulada del intervalo anterior al mediano.

n_i: la frecuencia absoluta del intervalo mediano.

a_i: la amplitud del intervalo mediano.

Ejemplo 2.4. Calcula la mediana de la siguiente tabla de frecuencias:

x_i	n_i	N_i
1	1	1
2	1	2
3	1	3
4	1	4
	$N = 4$	

Variable discreta y como $N_2 = \frac{4}{2}$, la mediana es $\dfrac{x_i + x_{i+1}}{2} = 2.5$

Ejemplo 2.5. Calcula la mediana de la siguiente tabla de frecuencias:

x_i	n_i	N_i
1	10	10
2	5	15
3	15	30
4	10	40
	$N = 40$	

Variable discreta y como $N_3 = 30 > \frac{40}{2} = 20$, la mediana es 3

Ejemplo 2.6. Calcula la mediana de los 10 primeros números naturales. *X= 10 primeros números enteros.* $x_1 = 1, x_2 = 2, \ldots, x_{10} = 10$, frecuencias $n_i = 1$, $i = 1, 2, \ldots, 10$, por lo tanto la variable es discreta (no agrupada). El vector de frecuencias acumuladas es $N_1 = 1, N_2 = 2, \ldots, N_{10} = 10$, el primer valor que es mayor o igual que $\frac{10}{2} = 5$ es $x_5 = 5$, como $N_5 = \frac{10}{2}$, entonces la mediana es $M_e = \frac{x_5 + x_6}{2} = 5.5$. Coincide con la media.

Ejemplo 2.7. Supón ahora que la ponderación de cada valor es inversamente proporcional a su valor. $x_1 = 1, x_2 = 2, \ldots, x_{10} = 10$, con pesos $w_i = \frac{1}{i}$, $i = 1, 2, \ldots, 10$, El vector de frecuencias acumuladas es

$(N_1 = 1, N_2 = 1.5, \ldots, N_{10} = 2.928968) = (1, 1.5, 1.83, 2.08, 2.28, 2.45, 2.59, 2.72, 2.83, 2.93)$, el primer valor que es mayor o igual que $\frac{2.928968}{2} = 1.464484$ es $x_2 = 1.5$, como es estrictamente mayor, entonces la mediana es $M_e = x_2 = 2$

Ejemplo 2.8. Calcula la mediana de la tabla agrupada del ejercicio 2.1 El vector de frecuencias acumuladas es $(N_1 = 10, N_2 = 42, N_3 = 92, N_4 = 100)$, el primer índice que es mayor o igual que $\frac{100}{2} = 50$ es $i = 3$, el intervalo es $(28, 32]$, como es estrictamente mayor, entonces la mediana es

$$M_e = 28 + \frac{50 - 42}{50} * 4 = 28 + \frac{32}{50} = 28 + 0.64 = 28.64$$

Usando el paquete de R *actuar*

```
> ### Calculo con R
>   #install.packages("actuar")
>   require(actuar)     # instalar el paquete actuar previamente!
>   Li <- c(0, 20, 28, 32, 48)      # limites de los intervalos
>   ni <- c(10,32,50,8)
>   x <- grouped.data(Group = Li, Frequency = ni)
>   #   x
>   quantile(x,probs=0.5)       # función quantile.grouped.data()
```

```
  50%
28.64
```

```
>   # codigo actuar:::quantile.grouped.data
>   hist(x, main="", xlab="") # función hist.grouped.data()
```

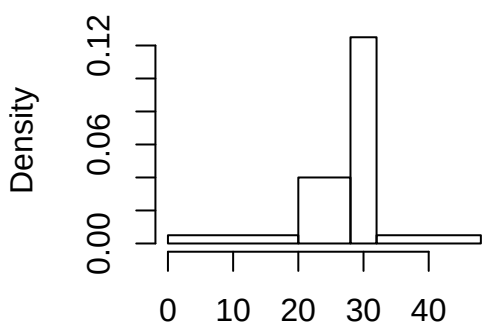

```
>   # codigo actuar:::hist.grouped.data
```

Moda (Mo): es el valor de la variable que más veces se repite, es decir, el más frecuente. La moda puede no ser única, puede haber una moda (variable unimodal), dos modas (bimodal), etc.

Cálculo de la moda:

- Distribuciones no agrupadas: valor de la variable de mayor frecuencia absoluta o relativa.
- Distribuciones agrupadas: el cálculo se realiza en dos estapas:
  - Detectar el *intervalo modal*: $[L_{i-1}, L_i)$ con mayor densidad de datos d_i.
  - Cálculo de la moda:

$$Mo = L_{i-1} + \frac{d_{i+1}}{d_{i+1} + d_{i-1}} a_i$$

siendo L_{i-1}: el extremo inferior del intervalo modal,

d_{i-1} y d_{i+1}: las densidades de frecuencia de los intervalos anterior y posterior al modal respectivamente. (En caso de no existir intervalo anterior o posterior se consideran igual a 0),

a_i: la amplitud del intervalo modal.

Ejemplo 2.9. Calcula la moda en el ejercicio de la tabla agrupada del Ejercicio 2.1 Dado el vector de densidades $(d_1 = 0.5, d_2 = 4, d_3 = 12.5, d_4 = 0.5)$, el intervalo (modal) con mayor densidad es $(28, 32]$. El valor de la moda es por lo tanto

$$Mo = 28 + \frac{0.5}{4 + 0.5} * 4 = 28 + \frac{2}{4.5} = 28 + 0.444 = 28.444$$

2.3.2 Medidas de posición no centrales: los Cuantiles

Se define *cuantil de orden p* con $0 < p < 1$ (x_p), como el valor que deja a lo sumo pN observaciones a su izquierda y $(1-p)N$ observaciones a su derecha. Destacamos en particular los cuantiles siguientes:

- Los *cuartiles* $(Q_1, Q_2$ y $Q_3)$: dividen a la distribución en cuatro partes iguales, dentro de cada cual están incluidos el 25% de los valores de la distribución.
- Los *deciles* $(D_1, D_2, \ldots, D_9)$: dividen a la distribución en diez partes iguales; dentro de cada una están incluidos el 10% de los valores.
- Los *percentiles* $(P_1, P_2, \ldots, P_{99})$: dividen a la distribución en cien partes iguales; dentro de cada una está incluido el 1% de los valores.

Cálculo del cuantil de orden p

1. Distribuciones no agrupadas: Se observa cuál es la primera frecuencia absoluta acumulada N_i que supera o iguala a pN distinguiéndose dos casos:
   - Si $N_i > pN$, entonces $x_p = x_i$.
   - Si $N_i = pN$, entonces $x_p = \dfrac{x_i + x_{i+1}}{2}$.
2. Distribuciones agrupadas: Primero se detecta el intervalo que contiene al cuantil: el primer $[L_{i-1}, L_i)$ con $N_i \geq pN$, luego se aplica la fórmula:

$$x_p = L_{i-1} + \frac{pN - N_{i-1}}{n_i} a_i = L_{i-1} + \frac{p - F_{i-1}}{f_i} a_i$$

Diagramas de caja

Este tipo de gráficos también se conocen como Box-Plots. Para construirlos es necesario el cálculo del primer y tercer cuartil Q_1 y Q_3. Se definen el extremo inferior y superior LI y LS respectivamente como:

$$LI = \max\left\{\min\{x_i\}, Q_1 - 3\left(\frac{Q_3 - Q_1}{2}\right)\right\} LS = \min\left\{\max\{x_i\}, Q_3 + 3\left(\frac{Q_3 - Q_1}{2}\right)\right\}$$

obteniéndose un diagrama de caja de la forma:

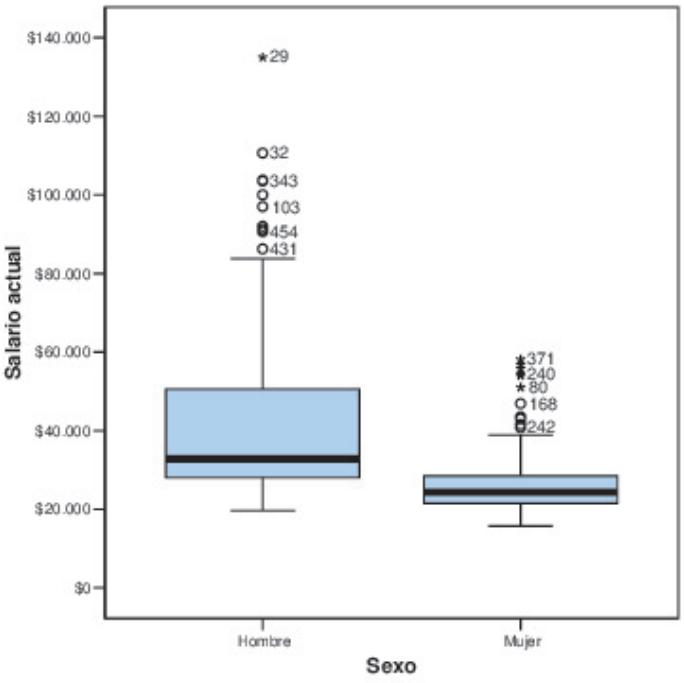

Ejercicio 2.5. Genera un diagrama de cajas de la variable Ancho del Pétalo en función del tipo de especie. ¿Qué conclusión en términos de los cuartiles de *Versicolor* podemos obtener?

Momentos Potenciales

Los momentos de una distribución son unos valores que la caracterizan, de tal modo que dos distribuciones son iguales si tienen todos sus momentos iguales, y son tanto más parecidas cuanto mayor sea el número de momentos iguales que tengan.

Momentos respecto al origen

El momento de orden r con respecto al origen se define como:

$$a_r = \frac{\sum_{i=1}^{k} x_i^r n_i}{N} = \sum_{i=1}^{k} x_i^r f_i$$

Los primeros momentos serán: $a_0 = 1$, $a_1 = \overline{x}$.

Momentos respecto a la media aritmética:

El momento de orden r con respecto a la media aritmética se define como:

$$m_r = \frac{\sum_{i=1}^{k} (x_i - \overline{x})^r n_i}{N} = \sum_{i=1}^{k} (x_i - \overline{x})^r f_i$$

Los primeros momentos serán: $m_0 = 1$, $m_1 = 0$, $m_2 = \dfrac{\sum_{i=1}^{k} (x_i - \overline{x})^2 n_i}{N} = s^2$.

Propiedad:

Utilizando el binomio de Newton, los momentos con respecto a la media se pueden expresar en función de los momentos con respecto al origen. En particular:

$$\begin{aligned} m_2 &= a_2 - a_1^2 \\ m_3 &= a_3 - 3a_2a_1 + 2a_1^2 \end{aligned}$$

Como ejercicio se propone expresar m_r los momentos respecto a la media aritmética de orden r en función de los momentos con respecto al origen.

Ejercicio 2.6. Sea r el valor de los dos últimos dígitos de tu DNI, calcula el momento de orden r centrado en el origen y en su media de la v. Sepal.Length del conjunto de datos iris.

2.3.3 Medidas de Dispersión

Son medidas que nos indican la desviación de los valores de la variable respecto de ciertas medidas de posición como la media aritmética o la mediana. A la mayor o menor separación de los valores respecto a otro, que se pretende sea su síntesis, se llama dispersión o variabilidad.

Medidas de Dispersión Absolutas:

Recorrido: es la diferencia entre el mayor valor y el menor valor de una distribución: $Re = x_k - x_1 = \max_{i=1\ldots k} x_i - \min_{i=1\ldots k} x_i$.

Recorrido Intercuartílico: es la diferencia existente entre el tercer cuartil y el primero: $IRQ = C_3 - C_1$.

Nos indica que en un intervalo de longitud IRQ están comprendidos el 50% de los valores centrales.

Varianza: De todas las medidas de dispersión absolutas respecto a la media aritmética, la varianza y su raíz cuadrada, la desviación típica son las más importantes.

$$s^2 = \frac{\sum_{i=1}^{k} (x_i - \overline{x})^2 n_i}{N}$$

Desviación típica o estándar: Es la raíz cuadrada de la varianza:

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^{k} (x_i - \overline{x})^2 n_i}{N}}$$

Propiedades de la varianza:

1. La varianza y la desviación típica **NUNCA** pueden ser negativas $s^2 \geq 0$, $s \geq 0$.
2. La varianza es la medida cuadrática de dispersión óptima, ya que:

$$\min_c \frac{1}{N} \sum_{i=1}^{k} (x_i - c)^2 n_i = \frac{1}{N} \sum_{i=1}^{k} (x_i - \overline{x})^2 n_i \text{ (Teorema de König)}$$

3. La varianza es igual al momento de segundo orden respecto al origen menos el de primer orden elevado al cuadrado.

$$s^2 = a_2 - a_1^2 = \left(\sum_{i=1}^{k} x_i^2 f_i \right) - \left(\sum_{i=1}^{k} x_i f_i \right)^2$$

4. Si en la distribución de frecuencias sumamos a todos los valores de la variable una constante, la varianza no varía (un cambio de origen no afecta a la varianza).

$$y_i = x_i + a \ ; \ s_Y^2 = s_X^2$$

5. Al multiplicar todos los valores de una distribución de frecuencias por una constante, la varianza queda multiplicada por el cuadrado de dicha constante.

$$y_i = bx_i \ ; \ s_Y^2 = b^2 s_X^2$$

Interpretación

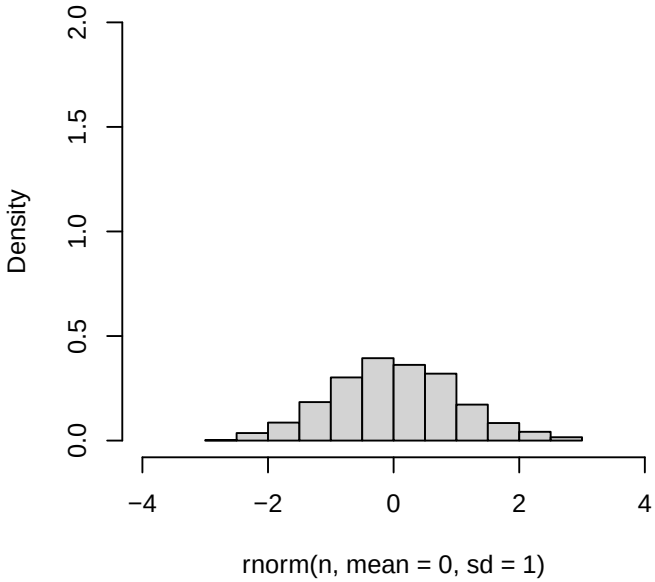
Density
0.0
0.5
1.0
1.5
2.0
−4
−2
0
2
4
rnorm(n, mean = 0, sd = 1)

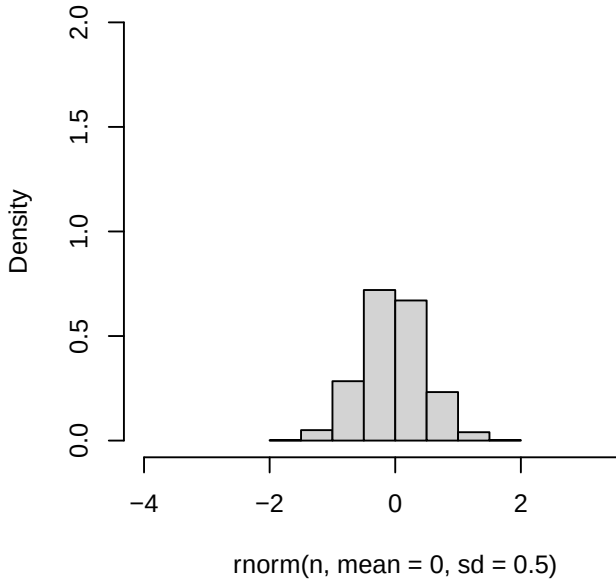
Density
0.0
0.5
1.0
1.5
2.0
−4
−2
0
2
rnorm(n, mean = 0, sd = 0.5)

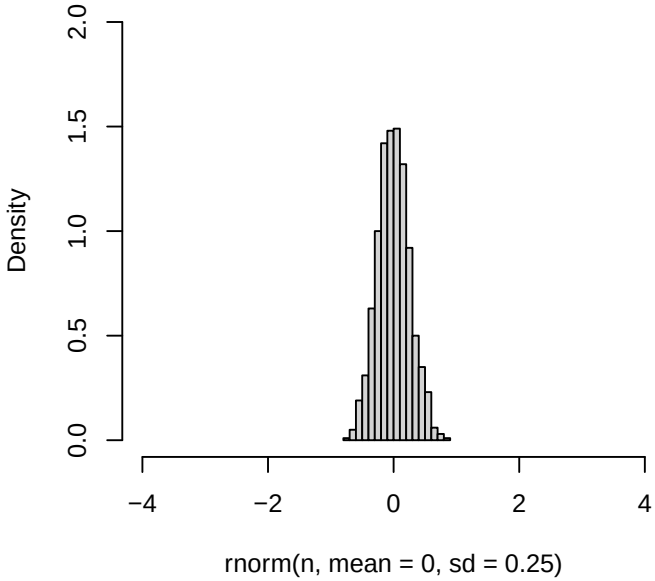
Density
0.0
0.5
1.0
1.5
2.0
−4
−2
0
2
4
rnorm(n, mean = 0, sd = 0.25)

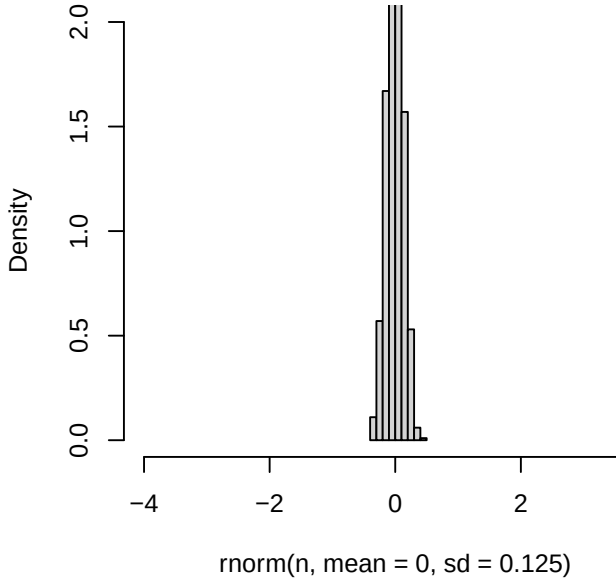
Density
0.0
0.5
1.0
1.5
2.0
−4
−2
0
2
rnorm(n, mean = 0, sd = 0.125)

Ejercicio 2.7. Dado el conjunto de datos *iris*, responde:

1. Agrupa la variable *Sepal.Length* en 8 intervalos de igual longitud. Usa el menú *Estadística Básica/Datos/Modificar el conjunto de datos activo/Segmentar variable numérica ....* Obtén su distribución de frecuencias completa.

2. Agrupa nuevamente pero en 8 intervalos con extremos 4 y 8. Usa el menú *Estadística Básica/Datos/Modificar el conjunto de datos activo/Recodificar ....* Obtén su distribución de frecuencias completa. Genera una nueva columna con la marca de clase

3. Compara la media da v. *Sepal.Length* agrupada y sin agrupar.

4. Comprueba la propiedad 5 de la media para la v. *Sepal.Length*, i.e., min(xi) <= media & media<= max(xi)

5. Recarga el conjunto de datos original y construye el histograma de la v. *Sepal.Length*.

6. Representa y compara en un gráfico la v. *Sepal.Length* en función del tipo de flor. Visualizando el gráfico, que se puede decir del 75% de las longitudes del Sepalo de la subespecie *setosa* con respecto a la subespecie *versicolor* y *virginica*. Y del 50% de la longitud del sepalo de la subespecie *virginica* con respecto a las otras.

7. Haz un resumen numérico de la v. *Sepal.Length* en función del tipo de subespecie.

8. Que proporción de valores de la v. *Sepal.Length* están dentro del intervalo $\bar{x} - 1.96 * sd_{Sepal.Length}, \bar{x} + 1.96 * sd_{Sepal.Length}$

9. Edita el conxunto de datos y pon el 1º valor de la v. *Sepal.Length* a 1000. Recalcula la media nuevamente. ¿Sigue siendo ese valor representativo de todas las longitudes del sepalo?.

10. ¿Qué valor representa ahora mejor la posición central?. Que ocurre si se pone el 2º valor= 1000?, y si se hace con el 3º valor también, e con el 4º, ... Cuantos valores se tienen que modificar para que se vea alterada esta nueva medida de posición central?.

11. Añade un valor para que la media de la variable *Petal.Length* sea

    4.

```
> head(iris)
```

```
  Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1          5.1         3.5          1.4         0.2  setosa
2          4.9         3.0          1.4         0.2  setosa
3          4.7         3.2          1.3         0.2  setosa
4          4.6         3.1          1.5         0.2  setosa
```

```
5          5.0         3.6          1.4         0.2  setosa
6          5.4         3.9          1.7         0.4  setosa
```

```
> x <- mean(iris$Petal.Length)
> # A media dos (150+1) datos é: (sum_xi + x0)/151 =4, de aquí despexando obtense
> x0 <- 150*(4*151/150 - x); x0
```

```
[1] 40.3
```

```
> # Comprobamos que o valor x0 é o correcto
> mean( c(iris$Petal.Length,x0))
```

```
[1] 4
```

12. Modifica un valor para que la media sea igual a la mediana da v. *Petal.Length*

```
> x <- mean(iris$Petal.Length)
> y <- median(iris$Petal.Length)
> xx <- iris$Petal.Length
> xx[length(xx)] <- xx[length(xx)] + 150*(y-x)
> # Comprobamos que o valor x0 é o correcto
> mean(xx); y
```

```
[1] 4.35
```

```
[1] 4.35
```

2.3.4 Medidas de Dispersión relativas

Si queremos comparar los promedios de dos distribuciones para saber cuál de los dos es más representativo debemos utilizar medidas adimensionales, es decir, que no vengan afectadas por las unidades de medida. Estas medidas de dispersión, llamadas relativas, siempre se concretan en forma de cociente. Las más utilizadas son:

Recorrido relativo: Se define como el cociente entre el recorrido y la media aritmética. Si $\overline{x} \neq 0$: $R_r = \frac{Re}{\overline{x}}$\$

Coeficiente de variación de Pearson: se define como la relación por cociente entre la desviación típica y la media aritmética. Si $\overline{x} \neq 0$

$$v = \frac{s}{\overline{x}}$$

Cuanto mayor sea v, menor es la representatividad de la media aritmética.

2.3.5 Medidas de Forma

Están relacionadas con la representación gráfica de la distribución. Pueden ser:

Medidas de simetría:

- Asimetría positiva: Si las frecuencias más altas se encuentran en el lado izquierdo de la media, mientras que en derecho hay frecuencias más pequeñas (cola).

- Asimetría negativa: Cuando la cola está en el lado izquierdo.

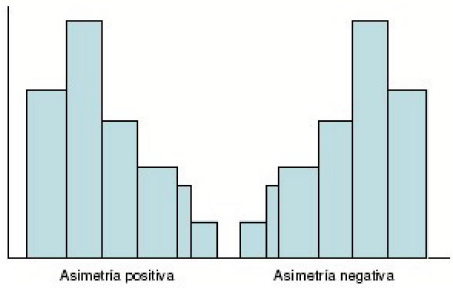

Coeficiente de asimetría de Fisher: $g_1 = \dfrac{m_3}{s^3}$

Para cada coeficiente, existen tres posibilidades: - $g_1 > 0$: La asimetría es positiva o por la derecha.

- $g_1 = 0$: La distribución es simétrica.

- $g_1 < 0$: La asimetría es negativa o por la izquierda.

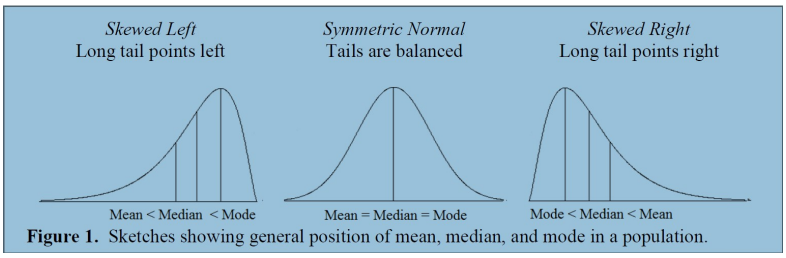

Figura: Extraído de: Doane, D.P., Seward, L.E. (2011). Measuring Skewness: A Forgotten Statistic?. *Journal of Statistics Education*, Volume **19**, Number 2.

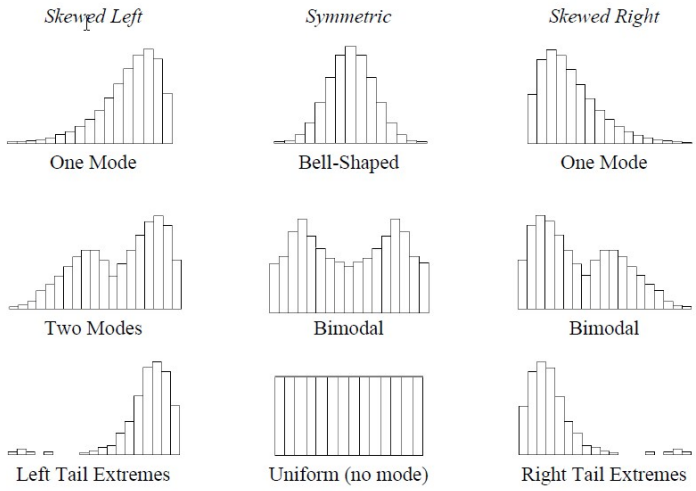

Figure 2. Illustrative prototype histograms.

Medidas de apuntamiento o curtosis

- Coeficiente de curtosis de Fisher: $g_2 = \dfrac{m_4}{s^4} - 3$
  - $g_2 > 0$: Distribución leptocúrtica: más apuntamiento que la distribución normal.
  - $g_2 = 0$: Distribución mesocúrtica: apuntamiento similar a la distribución normal.
  - $g_2 < 0$: Distribución platicúrtica: menos apuntamiento que la distribución normal.

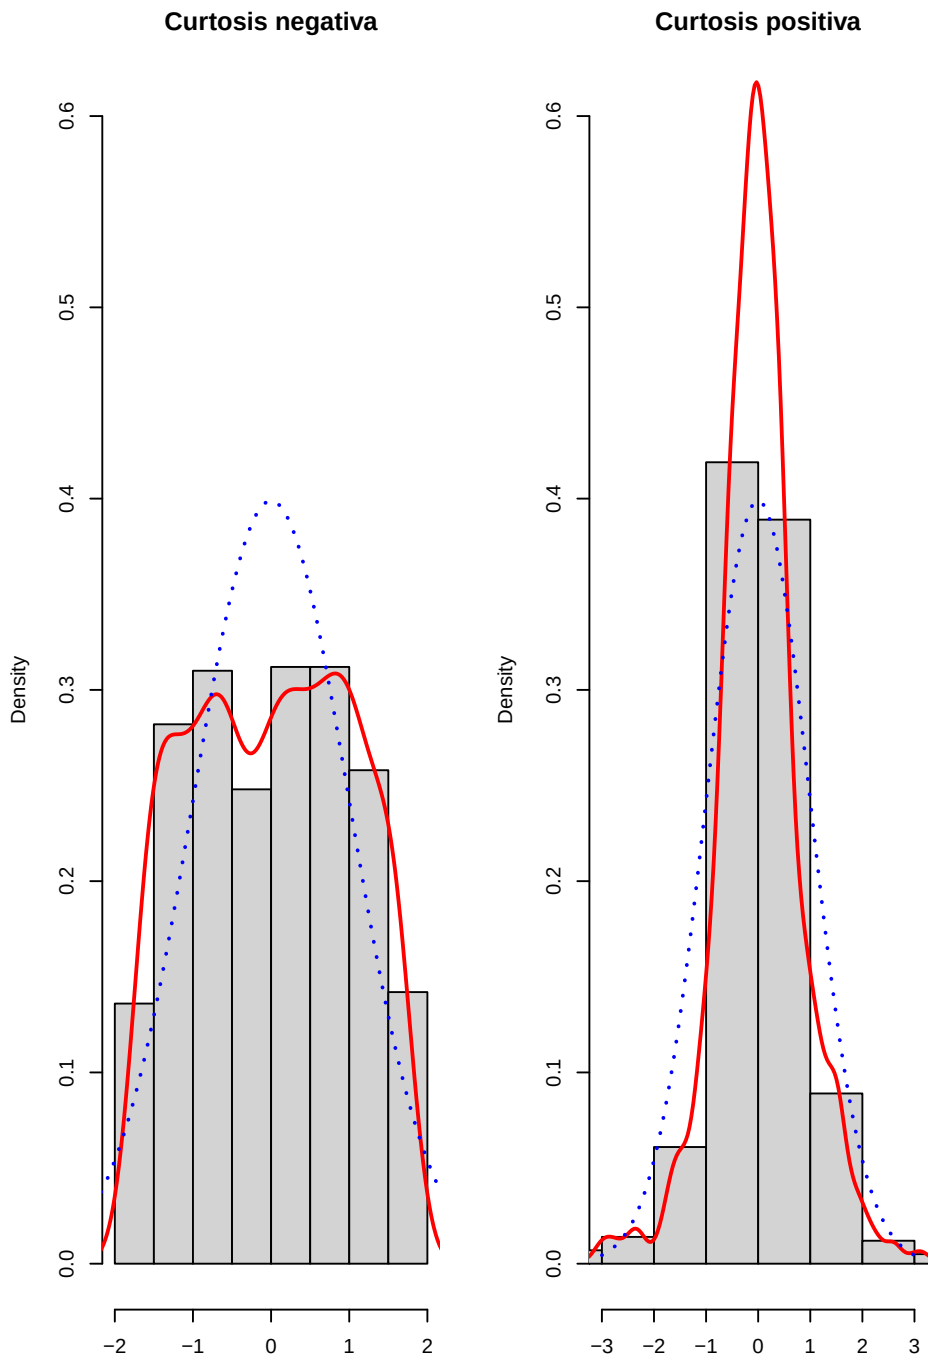
Curtosis negativa
Curtosis positiva
Density
Density
0.0
0.1
0.2
0.3
0.4
0.5
0.6
−2
−1
0
1
2
−3
−2
−1
0
1
2
3

Tipificación

Una variable estadística se dice tipificada o estandarizada si su media es cero y su varianza o su desviación típica es uno. Dada una variable X con media μ, y varianza σ^2, la nueva variable $Z = \dfrac{X-\mu}{\sigma}$, es su tipificada.

Ejercicio 2.8. Tipifica la variable *Sepal.Length* del conjunto de datos *iris* y comprueba que efectivamente la v. tipificada tiene media 0 y varianza 1. Menú *Estadística Básica/Datos/Modificar variables del conjunto de datos activo/Tipificar*.

```
> data(iris)
> iris <- local({
+   .Z <- scale(iris[,c("Sepal.Length")])
+   within(iris, {
+     Z.Sepal.Length <- .Z[,1]
+   })
+ })
>
> numSummary(iris[,"Z.Sepal.Length"], statistics=c("mean", "sd", "IQR", "quantiles"),
+   quantiles=c(0,0.25,0.5,0.75,1))
```

```
          mean sd      IQR       0%        25%         50%      75%     100%
 -4.480675e-16  1 1.569923 -1.86378 -0.8976739 -0.05233076 0.672249 2.483699
   n
 150
```