Manejo de RCommander: Archivos

Índice

Material **1**

1 ¿Qué es R y RCommander? **2**

2 ¿Cómo instalar R y RCommander? **2**
2.1 Forma genérica para cualquier sistema operativo 2
2.2 Forma sencilla 4

3 Breve introducción a R **5**
3.1 Entorno gráfico (GUI) 5
3.2 Librerías o paquetes 7
3.3 Obtención de ayuda 8

4 Actividades **8**

5 Sistema de ventanas con RCommander. **9**

6 Tipos de archivo en RCommander **9**
6.1 Crear, cargar, importar y guardar conjuntos de datos 10
6.2 Archivos de instrucciones 14
6.3 Archivos de resultados 15

7 Operaciones sobre los conjuntos de datos **15**
7.1 Cambiar tipo de variable. 16
7.2 Ordenar niveles de factor. 16
7.3 Ordenar datos. 17
7.4 Filtrar datos. 18
7.5 Eliminar niveles de factor sin uso 18
7.6 Recodificar una variable 19
7.7 Segmentar una variable numérica 20
7.8 Calcular una nueva variable. 21

8 Actividades **22**

Material

Descargar los siguientes archivos:

- `RcmdrPlugin.TeachStat_1.1.0.zip` (solo para Windows y Mac)
- `RcmdrPlugin.TeachStat_1.1.0.tar.gz` (solo para Linux)
- `Portable_R_TeachStat_1.1.0.zip`

1 ¿Qué es R y RCommander?

R es un lenguaje de programación, totalmente gratuito y accesible, cuya potencia de análisis estadístico supera a la de cualquier otro programa estadístico. RCommander es una interfaz gráfica (GUI) de R que permite un aprendizaje más cómodo del programa R. Ambos programas funcionan en los Sistemas Operativos más populares (Windows, Linux, MacOS) además de ser software libre. Su página web es:

http://www.r-project.org

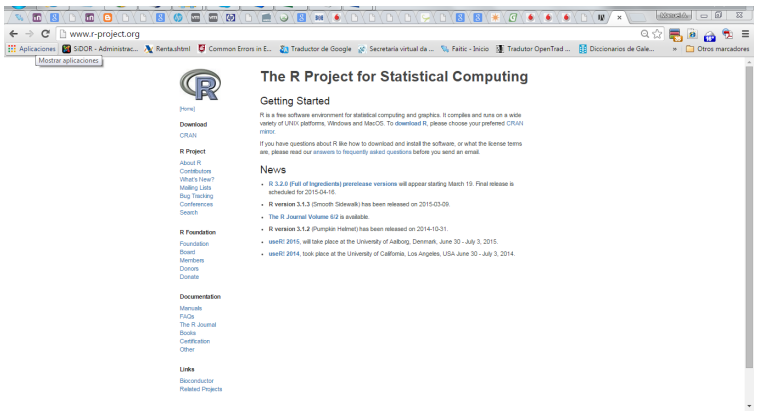

R está disponible en una serie de repositorios (mirrors, espejos, . . .) distribuidos en muchas universidades del mundo, de las cuales se puede descargar gratuitamente. Varias universidades han desarrollado cursos de estadística basados en R y en RCommander, por ejemplo la Universidad de Cádiz:

http://knuth.uca.es/moodle/

Aquí encontraréis un manual bastante completo de Estadística con R y RCommander.

2 ¿Cómo instalar R y RCommander?

Hay varias formas de instalar estos programas, se verá primero la forma genérica de instalación y posteriormente se indicará un método abreviado.

2.1 Forma genérica para cualquier sistema operativo

Seguir los siguientes pasos:

1. Instalar el software R: ir a la página http://www.r-project.org y en el menú de la izquierda acceder al apartado *Download* y pinchar en *CRAN*. De esa forma aparece una página web con distintos links de diferentes países donde tienen repositorio de este software.

2. Se busca aquel repositorio que nos interese o nos quede más cercano, en España tenemos dos:

3. Debemos elegir el sistema operativo de nuestro ordenador y descargar el archivo para proceder a la instalación:

4. En el caso de tener un sistema operativo **Windows**, descargaremos el archivo **base**:

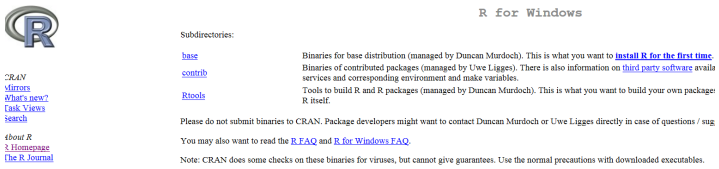

5. Una vez instalado el R, debemos ejecutarlo y aparece la llamada **consola de R.** La forma de ejecutarlo es distinta según el Sistema Operativo del que se disponga. En Windows, aparecerá un menú nuevo en el botón de Inicio.

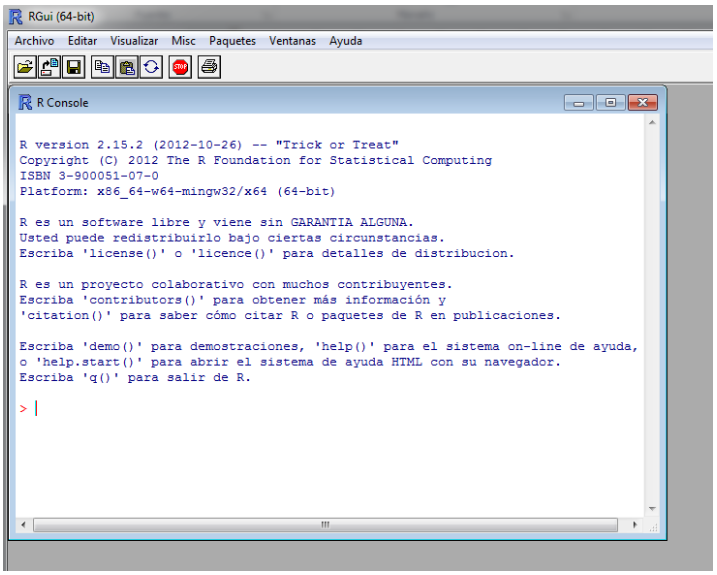

6. **Instalar el RCommander y el "plugin"** `RcmdrPlugin.TeachStat`:[1]
   - **Windows**: ir al menú: *Paquetes/Instalar paquete(s)*
   - **Linux:** ejecutar en la consola de R: `install.packages()`.
   - **Mac OS**: http://socserv.socsci.mcmaster.ca/jfox/Misc/Rcmdr/installation-notes.html.
7. A continuación sale un desplegable (sólo una vez por sesión) donde tenemos que elegir el repositorio (CRAN) de donde vamos a bajar el paquete.

[1]Para empezar a usar el RCommander solo sería necesario instalar el paquete `Rcmdr`. El "plugin" `RcmdrPlugin.TeachStat` es un añadido que facilita un poco la tarea de realizar un estdio estadístico básico.

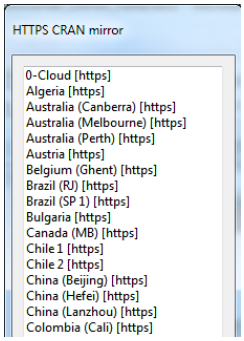

8. Finalmente aparece una lista de los paquetes de donde tenemos que elegir el correspondiente a RCommander, que es el `Rcmdr` y el correspondiente al plugin, que es el `RcmdrPlugin.TeachStat`.

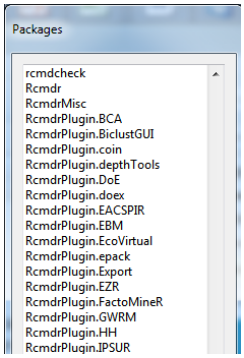

9. **Para ejecutar el RCommander:** escribir en la consola de R: `library(Rcmdr)`.
10. **Para cargar el plugin:** ir al menú de RCommander: *Herramientas/Cargar Plugin(s) de Rcmdr* y seleccionar `RCmdrPlugin.TeachStat`. Por defecto os indica que debe reiniciar el RCommander, aceptáis y ya estará cargado el paquete.

Notas:

- Si el plugin ha sido cargado correctamente, aparecerá un nuevo menú llamado *Estadística Básica*.
- El software R distingue entre mayúsculas y minúsculas y por tanto, los nombres "`datos`" y "`Datos`" son distintos.

2.2 Forma sencilla

Utilizar un archivo comprimido (.zip) que ya tienen todo lo necesario para ejecutar el programa sin necesidad de instalarlo:

2. Descargar el archivo comprimido (.zip) `Portable_R_TeachStat_?.zip` (? hace referencia a un número de versión, por ejemplo `1.1.0`),
3. **DESCOMPRIMIRLO en cualquier carpeta del ordenador**. Acceder a esta carpeta y
4. Ejecutar el programa
    1. **Windows:** Hacer doble clic en el archivo de nombre `R_TeachStat.exe`, que está en la carpeta descomprimida.
    2. **Linux y Mac OS:** es necesario instalar previamente el programa **WINE** (https://wiki.winehq.org/Download) que permite ejecutar programas de Windows en sistemas operativos Linux o Mac. Una vez hecho, para ejecutar el programa hay que abrir un terminal en la carpeta donde se haya descomprimido el programa y hacer doble click en el fichero `R_TeachStat.exe` o escribir: `wine R_TeachStat.exe`.

De esta forma se podrá utilizar el RCommander y el plugin, sin necesidad de instalarlo en el ordenador previamente.

3 Breve introducción a R

R es software libre se trata de un lenguaje de programación enfocado en realizar y facilitar el cálculo estadístico y gráfico. Por ese motivo tiene implementadas una gran variadad de técnicas y procedimientos estadísticos y gráficos. Además, al tratarse de software libre, cualquier persona con unos conocimientos mínimos de programación puede aportar nuevos procedimeintos o mejorar los ya existentes y ponerlos a disposición de toda la comunidad y de ahí viene su potencia (aunque a veces uno se pierde en la cantidad de aportaciones que tiene). Paar obtener más infomación consultar https://www.r-project.org/about.html.

3.1 Entorno gráfico (GUI)

Su entorno gráfico es muy austero pero permite realizar y ejecutar todo lo necesario:

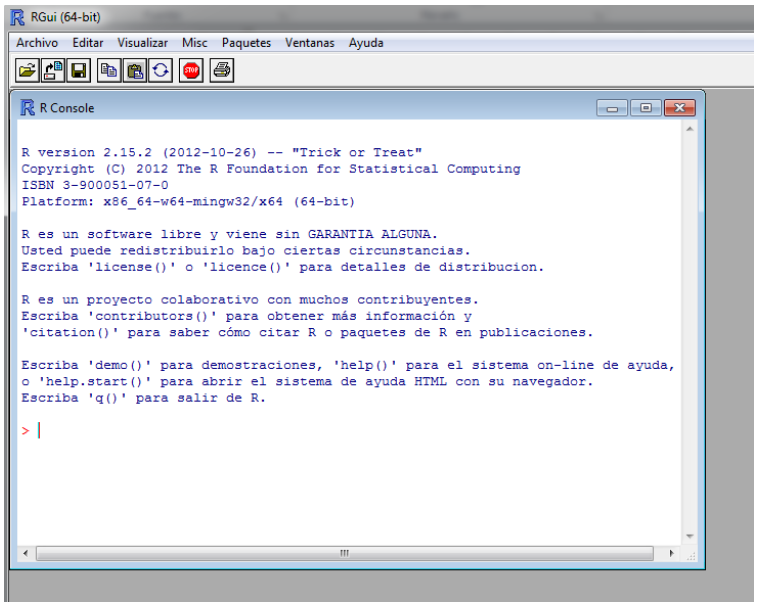

Se puede utilizar como simple calculadora, por ejemplo:

```
2+2
```

```
## [1] 4
```

```
(sqrt(2))^4
```

```
## [1] 4
```

También se puede hacer asignación de variables:

```
(x <- exp(5))
```

```
## [1] 148.4132
```

```
log(x)
```

```
## [1] 5
```

O realizar técnicas estadísticas más complejas:

```r
datos <- rnorm(100,mean=50,sd=5)
head(datos)
```

```
## [1] 51.34378 62.34599 53.17058 46.46646 53.12288 45.91829
```

```r
t.test(datos,mu=50,conf.level=0.99)
```

```
##
##  One Sample t-test
##
## data:  datos
## t = 0.13564, df = 99, p-value = 0.8924
## alternative hypothesis: true mean is not equal to 50
## 99 percent confidence interval:
##  48.49894 51.66455
## sample estimates:
## mean of x
##  50.08174
```

Y dibujar multitud de gráficos:

```r
opar <- par(mfrow=c(1,2))
hist(datos)
boxplot(datos,col="red")
```

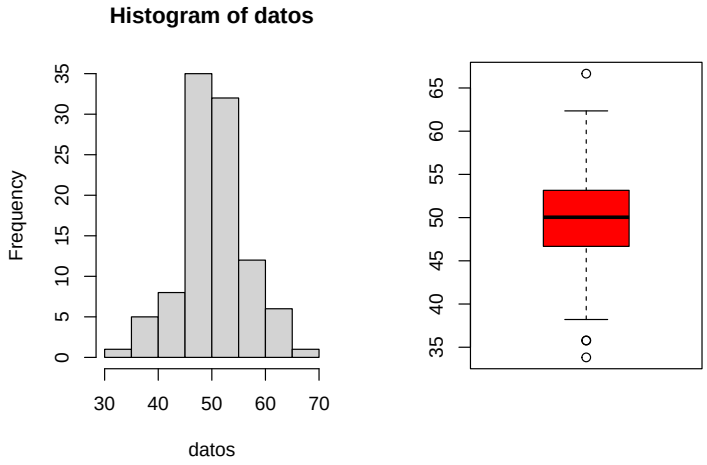


```r
par <- opar
```

Hay que tener cuidado porque R es sensible a mayúsculas y minúsculas, es decir, los nombres `datos` y `Datos` representan distintos objetos de R:

```r
Datos <- 10
datos <- "hola"
Datos
```

```
## [1] 10
```

```r
datos
```

```
## [1] "hola"
```

Como vemos anteriormente R tiene los clásicos tipos de valores, numéricos, cadenas de texto y lógicos. Además, permite gestionar otros tipos de valores especiales (y operar con ellos):

- NaN (Not a Number): es resultado de una indeterminación.
- Inf: R representa valores no finitos ($-\infty, +\infty$) como Inf y -Inf.
- NA (Not Available): valor no disponible.

```
x <- 1/0; x
```

```
## [1] Inf
```

```
x+Inf; x-Inf; log(x)+sqrt(x)
```

```
## [1] Inf
## [1] NaN
## [1] Inf
```

```
y <- NA; y
```

```
## [1] NA
```

```
y+0; y+x; is.na(y)
```

```
## [1] NA
## [1] NA
## [1] TRUE
```

3.2 Librerías o paquetes

La forma de aportar a R nuevas técnicas es a través de los llamados *paquetes* (durante la instalación ya hemos trabajado con alguno). Las técnicas estadísticas más habituales ya vienen instaladas por defecto en R (paquete `base` y `stats`), pero a veces necesitamos herramientas no tan comunes y lo primero que tenemos que hacer es buscar si algún paquete ya la tiene implementada. La mejor forma de buscar es utilizando Internet con las palabaras clave `R` (o `CRAN`, o `R-project`) y el nombre de la herramienta y como resultado obtendremos (si existe) el nombre del paquete que realiza esa técnica. Para instalarlo en R tendremos que ir al menú *Paquetes/Instalar paquete(s)...* (en Windows), seleccionar el espejo de donde descargarlo (si no se ha hecho ya) y seleccionar el paquete desde la (larga) lista mostrada (está ordenada alfabéticamente):

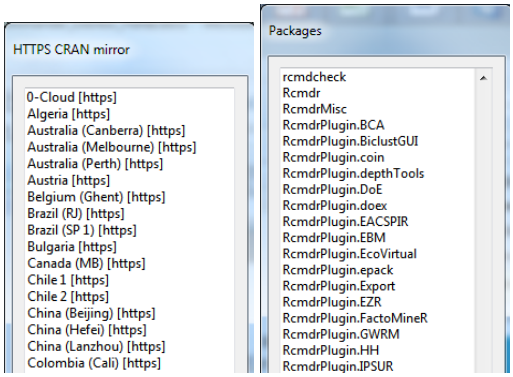

Los paquete pueden depender a su vez de otros paquetes (`dependencies`) lo cual hará necesario que se instalen previamente. Al realizar la instalación utilizando el procedimeinto anterior, por defecto ya se instalarán todas las dependecias. En caso de que no fuese así habría que utilizar el parámetro `dependencies=TRUE` en la llamada a la función `install.packages`.

Se puede dar el caso de que un determinado paquete no esté disponible en el repositorio de R (CRAN) pero del que dispongamos su archivo de instalación. En este caso, el archivo debería de tener la extensión `.zip` o

`.tar.gz` y para instalarlo utilizariamos el menú *Paquetes/Install package(s) from local file...* (Windows). Si el paquete tuviese dependencias, sería necesario instalarlas previamente.

Que se tenga instalado el paquete no quiere decir que ya se pueda utilizar directamente. Para ello será necesario cargar el paquete utilizando la orden `library("nombre_paquete")` o ir al menú *Paquetes/Cargar Paquete...* (en Windows). La siguiente instrucción nos dará un listado de todos los paquetes instalados en el ordenador:

```
library()
```

```
##      Package
## [1,] "abind"
## [2,] "actuar"
## [3,] "ade4"
## [4,] "AeRobiology"
## [5,] "afex"
## [6,] "AID"
##      Title
## [1,] "Combine Multidimensional Arrays"
## [2,] "Actuarial Functions and Heavy Tailed Distributions"
## [3,] "Analysis of Ecological Data: Exploratory and Euclidean Methods\nin Environmental Sciences"
## [4,] "A Computational Tool for Aerobiological Data"
## [5,] "Analysis of Factorial Experiments"
## [6,] "Box-Cox Power Transformation"
```

NOTA: salvo los paquetes básicos, el resto de paquetes es necesario cargarlos en cada sesión de R (los cuales deberían estar instalados previamente).

3.3 Obtención de ayuda

Para obtener ayuda sobre una determinada función lo más comodo es escribir:

```
?install.packages
```

o

```
help("install.packages")
```

En caso de desconocer el nombre de la función, se puede realizar una búsqueda utilizando una cadena de caracteres:

```
help.search("install packages")
```

4 Actividades

1. El paquete `MASS` contiene funciones y conjuntos de datos utilizados en el libro *"Modern Applied Statistics with S"* de B. Venables y B. Ripley:
   a) Buscar información sobre el paquete relativa a su instalación.
   b) Instalar el paquete y sus dependencias (si las hubiese).
   c) Cargar el paquete y buscar ayuda de la función `area`.
   d) Con la función del apartado anterior calcular el área encerrada por la función `sin(x)` entre 0 y π.
   e) Ejecutar el siguiente comando en la consola de R: `plot(sin,xlim=c(0,pi))`

5 Sistema de ventanas con RCommander.

La ventana del RCommander tiene el siguiente aspecto y se divide en 4 partes:

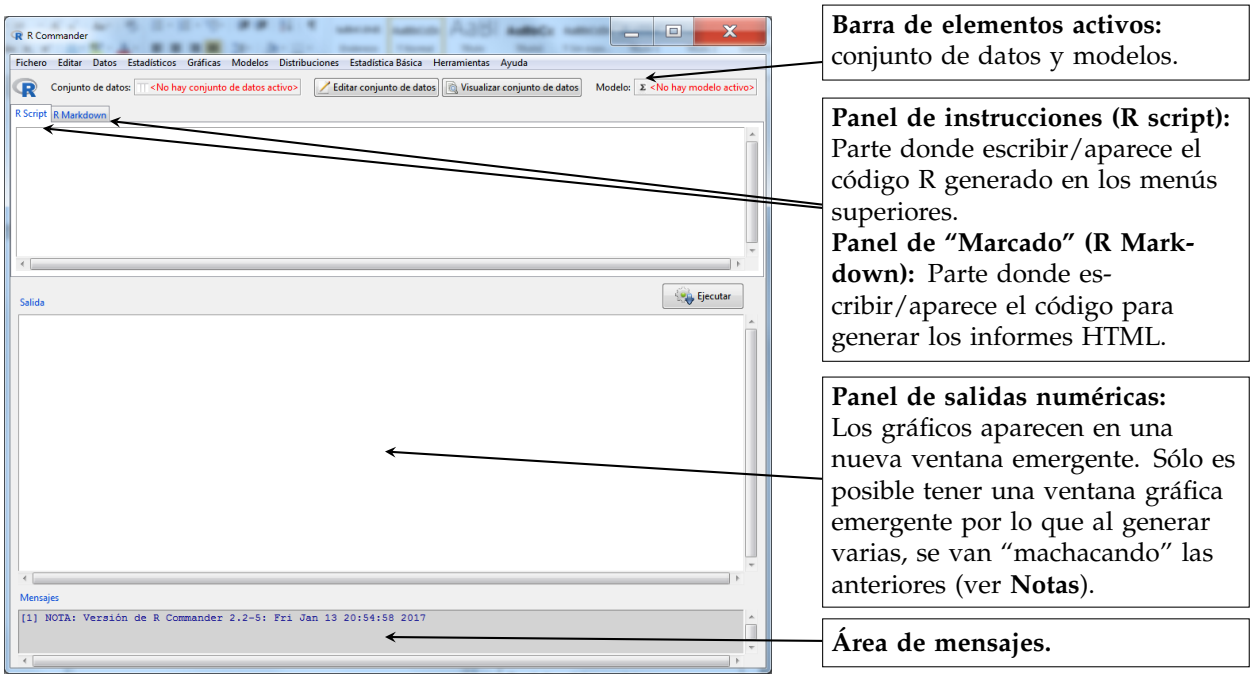

6 Tipos de archivo en RCommander

1. Archivos de *conjuntos de datos* (con extensiones `.RData`, `.RDat`, `.rds`).
2. Archivos de *instrucciones*, es un fichero de texto que se puede abrir con un editor simple de texto. Son archivos con extensión `.R` (Menús `Fichero/Abrir` `Fichero/Guardar` archivo de instrucciones)
3. Archivos de *resultados*, se pueden considerar varios tipos de resultados en función de la *salida*:

   3.1 Resultados en texto que aparecen en la ventana de salida del RCommander. No guarda las gráficas. Es un fichero `.txt` (Menús `Fichero/Abrir` `Fichero/Guardar` resultados).

   3.2 Resultados de gráficos cuando aparecen las ventanas gráficas. En el menú *Archivo/Guardar como...* se pueden guardar los gráficos en formatos Metafile/bmp/jpeg/png/tiff/pdf.

   3.3 Resultados de texto y gráficos creando archivos *RMarkdown*. Es un fichero con extensión `.Rmd` que puede ser compilado y generar un html con los resultados de la sesión. Aquí sí que genera las gráficas del archivo. Al lado de la pestaña de *R Script*, aparece otra pestaña con *R Markdown*. Ahí podemos ver y modificar el archivo RMarkdown. Para ver el fichero html resultante sólo tenemos que pinchar en el botón de **Generar Informe** situado entre las dos ventanas del RCommander.

Una guía simple sobre el manejo de RCommander puede encontrarse en el menú *Ayuda/Introducción a R Commander*. Se trata de la traducción al castellano de uno de los manuales sobre *"Iniciación a R Commander"* de John Fox. Son especialmente relevantes las secciones de "3. Input data" y "6. Odds and Ends" (distribuido con el paquete Rcmdr y accessible via el menú de ayuda -> Introduction to the R Commander menu). Con respecto a esta última sección es muy importante que guardéis el fichero de instrucciones y los conjuntos de datos, pues será lo necesario para poder reproducir los resultados o continuar con el análisis.

Notas:

- Para que al generar gráficos no se machaquen todos en la misma ventana y sólo se pueda acceder al último realizado, para el primer gráfico que realicéis tenéis que ir al menú *Herramientas* de la ventana gráfica y marcar la opción *"Grabando"* y la opción *"Agregar"*.
- Para importar un conjunto de datos desde Excel es mejor convertir el fichero de Excel en un fichero de texto con valores separados por comas (`.csv`) y después importarlo en RCommander como un fichero de texto. La opción de importarlo directamente de Excel (o de cualquier otro programa) no siempre funciona bien.

6.1 Crear, cargar, importar y guardar conjuntos de datos

De forma general la primera tarea que se realiza con R y RCommander es cargar un conjunto de datos sobre los cuales vamos se va a ejecutar los distintos procedimientos estadísticos/gráficos.

6.1.1 Crear un conjunto de datos nuevo.

RCommander dispone de un editor de datos en el menú *Datos/Nuevo conjunto de datos ...* (Imagen superior izquierda), en donde inicialmente debemos introducir un nombre (Imagen inferior izquierda - este debe seguir unas determinadas reglas, sin espacios, sin carácteres especiales, ...). Posteriormente aparece el *Editor de datos* (Imagen derecha) en el cual usando los botones `Añadir fila`, `Añadir columna` podemos incrementar el número de datos/variables.

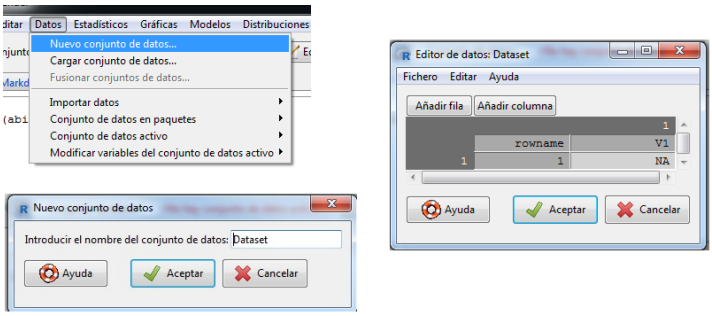

Hay que tener en cuenta que los datos se almacenan en R (y en todo el software estadístico) con una estructura matricial, por ejemplo, si se disponen de datos de sexo, peso y altura de 5 chicos y 5 chicas en edades de 1 a 5 años, se almacenan en una matriz 10 x 4. Destacar que las variabes se inicializan con `NA`, es decir el valor indicador de dato missing.

Como actividad se propone crear el conjunto de datos se muestra en la siguiente tabla.

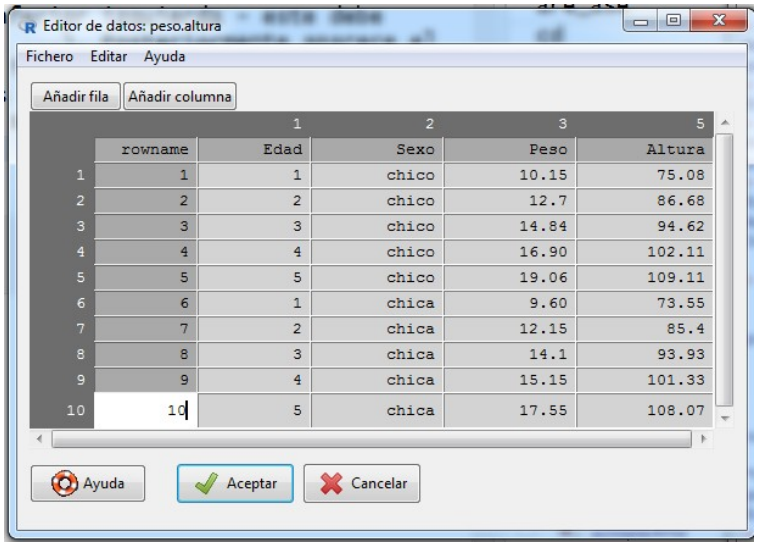

	rowname	Edad	Sexo	Peso	Altura
		1	2	3	5
1	1	1	chico	10.15	75.08
2	2	2	chico	12.7	86.68
3	3	3	chico	14.84	94.62
4	4	4	chico	16.90	102.11
5	5	5	chico	19.06	109.11
6	6	1	chica	9.60	73.55
7	7	2	chica	12.15	85.4
8	8	3	chica	14.1	93.93
9	9	4	chica	15.15	101.33
10	10	5	chica	17.55	108.07

Nota: El separador decimal en R es el punto decimal.

Se recomienda no usar la columna `rowname` la cual se genera automáticamente.

6.1.2 Cargar un conjunto de datos.

Si se dispone de un conjunto de datos en formato de R (extensión `.RData` o `.Rdat`) podemos abrirlo desde el menú *Datos/Cargar conjunto de datos*. . . . Por ejemplo, el conjunto de datos en formato de R del gráfico anterior está disponble como archivo `altura-peso.RData`.

Adicionalmente R dispone de conjunto de datos que están incluídos en los paquetes que se instalan. Para acceder a ellos vamos al menú *Datos/Conjunto de datos en paquetes/Leer conjunto de datos desde paquete adjunto* . . . . Por ejemplo, el archivo de datos `cars93` del paquete `RcmdrPlugin.TeachStat`, para ello una vez cargado el paquete `RcmdrPlugin.TeachStat`

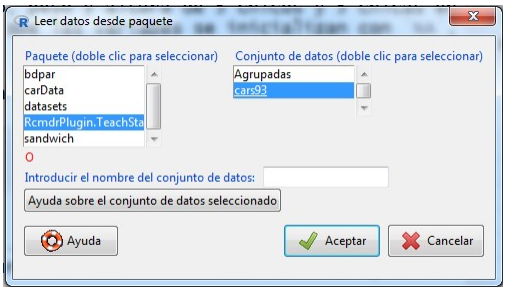

Para manejar el conjunto de datos disponemos de:

- *Editar Conjunto de datos*: se puede modificar los datos de las variables del archivo.
- *Visualizar conjunto de datos*: se puede ver, pero no modificar, los datos del archivo.

6.1.3 Importar conjunto de datos desde archivo

R y RCommander pueden importar archivos de muy distintos tipos: csv, txt, excel, spss, etc. En el menú de *Datos/Importar datos* o alternativamente *Estadística Básica/Datos/Importar datos*, podemos ver varias opciones para importar datos.

Veremos como realizar esta importación con un ejemplo. Vamos a importar el fichero de texto, `CPU.txt` (disponible en `Datos.zip`). Datos extraidos del repositorio `UCI - machine learning repository`. Las información viene dada por:

- *vendor* name: 30
- *Model* Name: many unique symbols
- *MYCT*: machine cycle time in nanoseconds
- *MMIN*: minimum main memory in kilobytes
- *MMAX*: maximum main memory in kilobytes
- *CACH*: cache memory in kilobytes
- *CHMIN*: minimum channels in units
- *CHMAX*: maximum channels in units
- *PRP*: published relative performance
- *ERP*: estimated relative performance from the original article

Para ello seguiremos los siguientes pasos:

1. Abrimos el fichero con un editor de texto plano (Bloc de Notas, Notepad++, . . .) para ver su estructura.

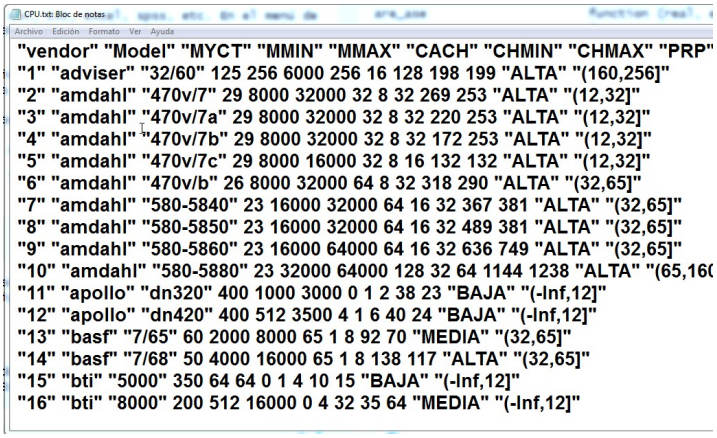

2. Vamos al menú *Estadística Básica/Datos/Importar datos desde archivo de texto...*
3. Completamos la ventana con el nombre al archivo y chequeamos las opciones que aparecen: ubicación del fichero, el separador de campos, el carácter decimal, ...

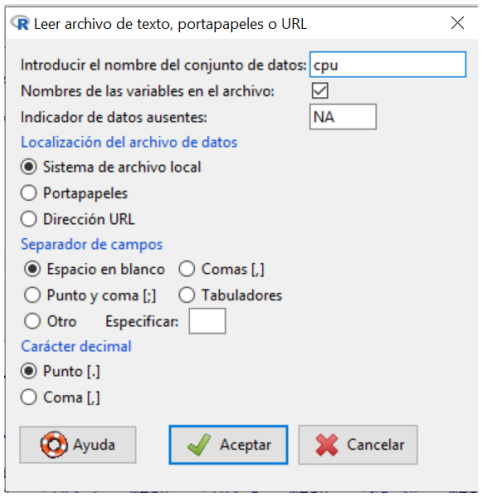

NOTA: Los nombres válidos en R comienzan con una letra mayúscula o minúscula, o un punto (.) y están compuestos íntegramente por letras, puntos, subrayados (_), y dígitos (es decir, 0–9); en particular no incluye blancos dentro del nombre del conjunto de datos.

6.1.4 Guardar Archivo de Datos

Una vez abierto, el archivo no está guardado, es necesario guardarlo en el formato de R (`.RData`) para no perderlo al cerrar la sesión de R. Para ello vamos al menú de *Datos/Conjunto de datos Activo/Guardar el conjunto de datos activo*

```
cpu <- read.table("./datos/CPU.txt",   header=TRUE, sep="", na.strings="NA", dec=".", strip.white=TRUE)
save("cpu", file="cpu.RData")
attach(cpu)
```

Cuando se quiera volver a utilizar un conjunto de datos que ya está guardado en formato de R (`.RData`) simplemente hay que ir al menú *Estadística Básica/Datos/Cargar conjunto de datos...*:

```
load("./datos/cpu.RData")
```

6.1.5 Obtención de datos de internet

Existen muchas vias para obtener datos en internet. Aquí os mostraremos como obtener algunos datos de la página web del Instituto Gale de Estadística (IGE):

1. Acceder al apartado *"Poboación -> Padrón municipal de habitantes e Nomenclátor -> Poboación segundo sexo e grupos quinquenais de idade"*:
2. Seleccionamos (ver imagen) el año correspondiente, en Sexo seleccionamos "Total", todos los grupos de edad salvo "Total", y el municipio de "Ourense".

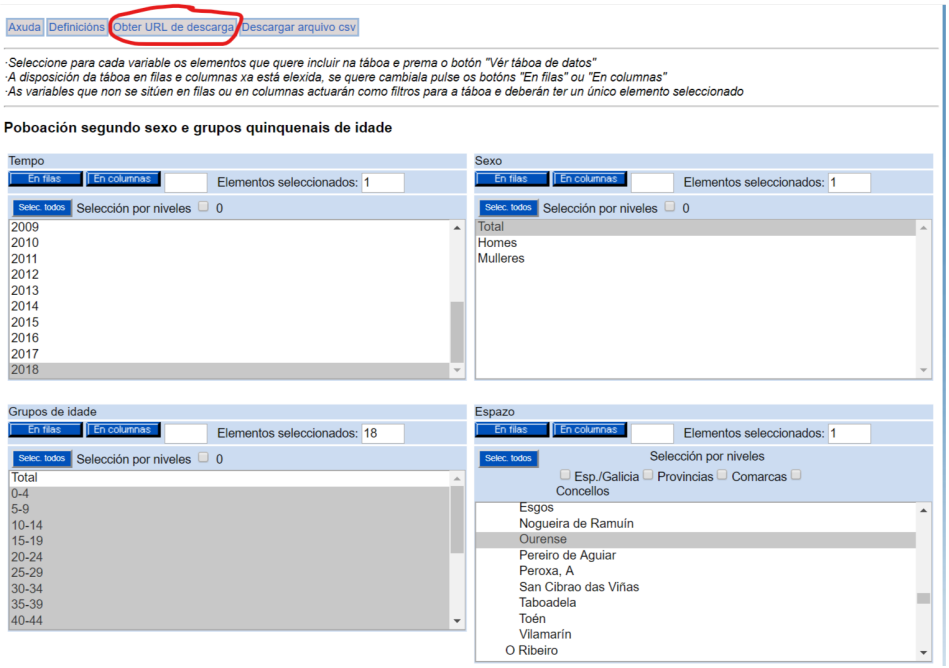

3. Para importar los datos al RCommander, lo más cómodo es pinchar en Obter URL de descarga, con lo cual obtendremos:

`http://www.ige.eu/igebdt/igeapi/datos/100/0:2018,1:0,2:1:2:3:4:5:6:7:8:9:10:11:12:13:14:15:16:17:18,991`

4. Ahora en RCommander vamos a *Datos/Importar datos/desde archivo de texto, portapapeles o URL...* y seleccionamos, tal como aparece en el siguiente gráfico:

   - Nombre del conjunto de datos: Poblacion
   - Dirección URL
   - Separador de campos: Coma
   - Carácter decimal: Coma[,]

   Después de darle a Aceptar pegamos la dirección URL que obtuvimos en la página web del IGE:

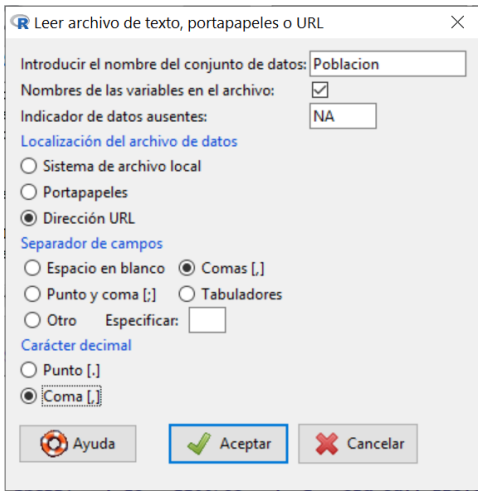


```
Poblacion <-
  read.table("https://www.ige.gal/igebdt/igeapi/csv/datos/142/0:2024,1:0,2:1:2:3:4:5:6:7:8:9:10:11:12:1
             na.strings="NA",dec=",", strip.white=TRUE)
head(Poblacion)
```

```
##   CodTempo Tempo  Sexo Grupos.de.idade CodEspazo       Espazo DatoN DatoT
## 1     2024  2024 Total             0-4      3205 3205 Ourense  4035 4.035
## 2     2024  2024 Total             5-9      3205 3205 Ourense  5437 5.437
## 3     2024  2024 Total           10-14      3205 3205 Ourense  6384 6.384
## 4     2024  2024 Total           15-19      3205 3205 Ourense  6640 6.640
## 5     2024  2024 Total           20-24      3205 3205 Ourense  6255 6.255
## 6     2024  2024 Total           25-29      3205 3205 Ourense  6425 6.425
```

Nota: El RCommander puede tener varios archivos de datos abiertos al mismo tiempo, pero **sólo uno activo**. Para saber cuál es el activo vemos debajo del menú el nombre que está en color azul al lado de *Conjunto de Datos*. Si queremos cambiar de conjunto de datos activo, sólo tenemos que pinchar en el nombre del conjunto, en color azul, y aparecerá un desplegable con los conjuntos abiertos en ese momento.

6.2 Archivos de instrucciones

En la ventana de `R Script` van apareciendo el código que se ejecuta al pinchar en el botón `Aceptar` de las ventanas de RCommander. Estas instrucciones se corresponden con los menús superiores. Además de poder modificar el código que aparece (y también incluir nuevo código) podemos ejecutarlo usando el boton `Ejecutar` entre el panel `Rscript` y `Salida`. Para ello solamente tenemos que seleccionar la parte de código que queremos ejecutar.

Nota: Las ejecuciones realizadas con este mecanismo pueden no ser detectadas con el RCommander, es decir, si modificamos una variable posiblemente RCommander no actualice la variable. Es recomendable después de realizar este tipo de operaciones actualizar el conjunto de datos en el menú *Datos/Conjunto de datos activo/Actualizar conjunto de datos activo*.

6.2.1 Cargar/Guardar archivos de instrucciones

Los archivos de instrucciones se guardan desde el menú *Fichero/Guardar las instrucciones* ... con la extensión `.R`. Estos archivos están en formato código ASCII plano y por lo tanto se pueden abrir/modificar/crear con cualquier editor de datos (Notepad, Word, ...)

6.3 Archivos de resultados

Las salidas de los procedimientos estadísticos (menús) aparecen en la ventana `Salida` junto con el código generado. Estas salidas se pueden copiar o guardar usando el menú *Fichero/Guardar resultados*. El formato del archivo de resultados es un `.txt`. Si la salida es un gráfico, se abre una ventana gráfica:

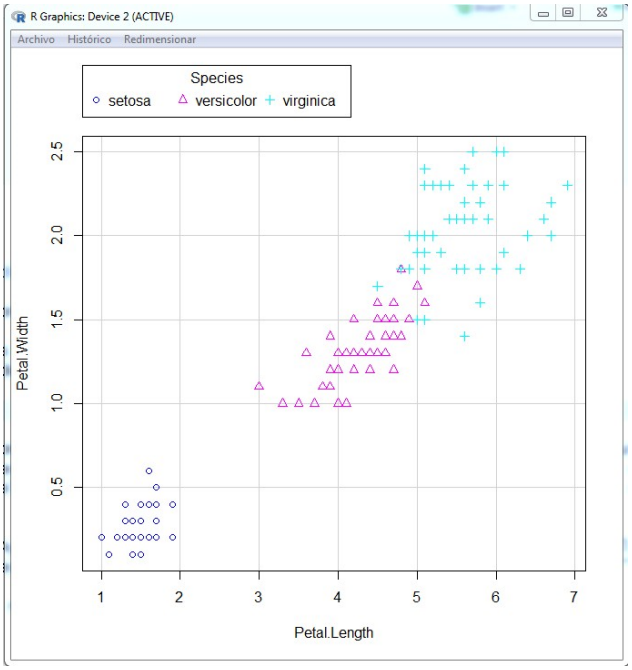

En el menú *Archivo/Guardar como...* se pueden guardar los gráficos en formatos Metafile/bmp/jpeg/png/tiff/pdf.

6.3.1 Archivos Markdown

Este tipo de archivos permite guardar resultados de texto y gráficos con un formato muy sencillo. Es un fichero con extensión `.Rmd` que puede ser compilado y generar un html (o docx, rtf, tex, pdf) con los resultados de la la sesión. Al lado de la pestaña de *R Script*, aparece otra pestaña con *R Markdown*. Ahí podemos ver y modificar el archivo RMarkdown. Para ver el fichero html resultante sólo tenemos que pinchar en el botón de **Generar Informe** situado entre las dos ventanas del RCommander.

Cada operación generada con los menús de RCommander se obtiene un `chunk` (código entre delimitadores), que se va añadiendo al final del archivo. Podemos editar el documento RMarkdown (*Editar/Editar el documento RMarkdown*) y añadir/formatear el texto. Más información en estos enlaces 'R Markdown from R-Studio' o en el 'libro'

7 Operaciones sobre los conjuntos de datos

Vamos a realizar diversas operaciones con las variables del archivo `cpu.txt` abierto anteriormente. Empezaremos con la revisión de la clasificación de las variables.

7.1 Cambiar tipo de variable.

Lo primero que hay que hacer después de obtener los datos es comprobar si estos están bien clasificados (ver la sección 1.2 del Tema 1 Estadística Descriptiva para la definición de variable nominal, ordinal, discreta y continua). Por ejemplo, existen procedimientos estadísticos para variables categóricas que no se pueden aplicar a variables continuas. El plugin de `RcmdrPlugin.TeachStat` aporta el menú *Estadística Básica/Datos/Conjunto de datos activo/Variables y tipos del conjunto de datos activo* para realizar esta tarea:

```
listTypesVariables("cpu")
```

```
##  [1] "vendor[factor]"              "Model[factor]"
##  [3] "MYCT[integer]"               "MMIN[integer]"
##  [5] "MMAX[integer]"               "CACH[integer]"
##  [7] "CHMIN[integer]"              "CHMAX[integer]"
##  [9] "PRP[integer]"                "ERP[integer]"
## [11] "ERP_agrup[ordered factor]"   "CACH_agrup[ordered factor]"
```

En este caso no estarían bien clasificadas las variables variables `ERP_agrup` y `CACH_agrup` ya que serían variables cualitativas **ordinales** y deberían estar catalogadas como **ordered factor**. Para cambiar el tipo de variable vamos al menú *Estadística Básica/Datos/Modificar variables del conjunto de datos activo/Cambiar tipo de variables...* y, utilizando los botones que aparecen en la ventana, colocamos cada variable en su tipo correspondiente:

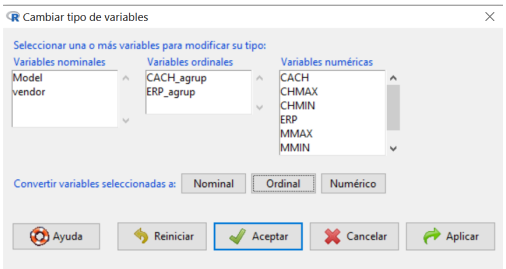


```
cpu <- within(cpu, {
  CACH_agrup <- as.ordered(CACH_agrup)
  ERP_agrup <- as.ordered(ERP_agrup)
})

listTypesVariables("cpu")
```

```
##  [1] "vendor[factor]"              "Model[factor]"
##  [3] "MYCT[integer]"               "MMIN[integer]"
##  [5] "MMAX[integer]"               "CACH[integer]"
##  [7] "CHMIN[integer]"              "CHMAX[integer]"
##  [9] "PRP[integer]"                "ERP[integer]"
## [11] "ERP_agrup[ordered factor]"   "CACH_agrup[ordered factor]"
```

7.2 Ordenar niveles de factor.

En una variable cualitativa ordinal es muy importante que los distintos valores (niveles) que puede tomar la variable estén ordenados. Por defecto, R ordena los niveles de un factor utilizando el orden alfabético y este puede no ser el adecuado. En el caso del conjunto de datos `cpu`, los nives de las variables ordinales no están bien ordenados y para proceder a su correcta ordenación hay que ir al menú *Estadística Básica/Datos/Modificar Variables del Conjunto de Datos Activo/Reordenar Niveles de Factor...*

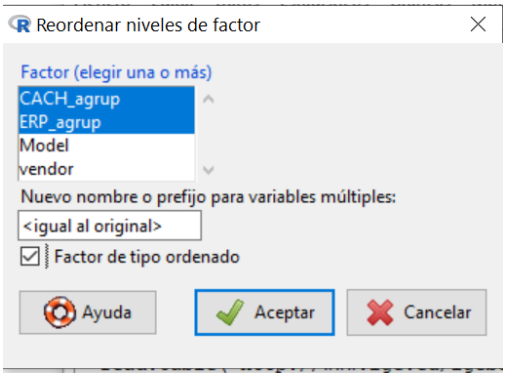

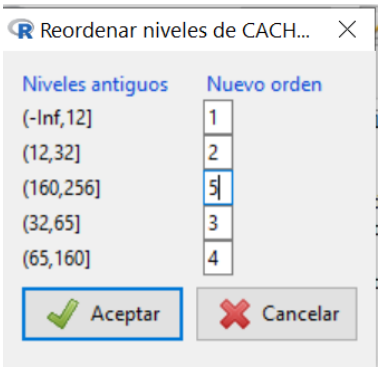

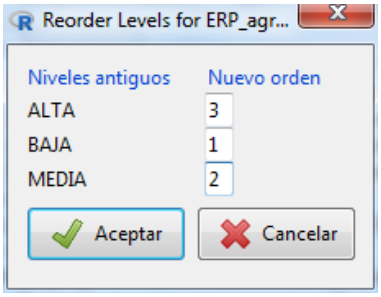


```
cpu <- within(cpu, {
  CACH_agrup <- factor(CACH_agrup, levels=c('(-Inf,12]','(12,32]','(32,65]','(65,160]',
                                            '(160,256]'), ordered=TRUE)
  ERP_agrup <- factor(ERP_agrup, levels=c('BAJA','MEDIA','ALTA'),ordered=TRUE)
})
```

7.3 Ordenar datos.

Se puede ordenar el conjunto de datos en función de una variable numérica existente (en sentido creciente o decreciente) y se puede guardar el resultado en un fichero nuevo. Para ello se utilizará el menú de *Estadística Básica/Datos/Conjunto de datos activo/Ordenar el conjunto de datos activo...*.

Como ejemplo vamos a ordernar el conjunto de datos `cpu` en sentido creciente de memoria caché (variable `CACH`) y guardar el resultado en un nuevo fichero que llamaremos `CPU_ord`.

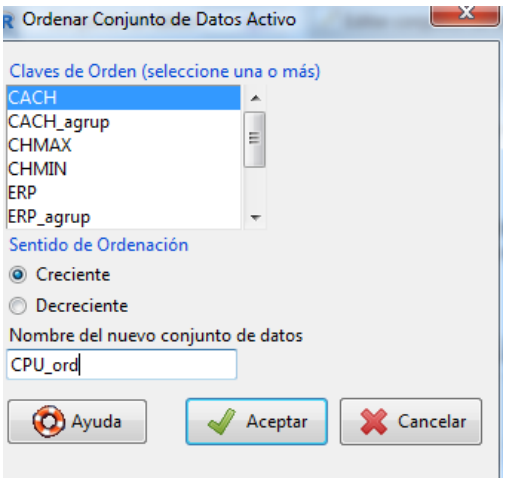

```
CPU_ord <- with(cpu, cpu[order(CACH, decreasing=FALSE), ])
```

7.4 Filtrar datos.

Podemos filtrar el conjunto de datos en función de características de sus variables en el menú de *Estadística Básica/Datos/Conjunto de datos activo/Filtrar el conjunto de datos activo...*.

Supongamos que queremos filtrar el conjunto de datos `cpu` (cuidado con el conjunto de datos que está activo) y quedarnos sólo con los casos donde la memoria caché está entre 30 y 160, ambos inclusive, y guardar el resultado en un fichero llamado `CPU_FILTRADO`. La orden de filtrado que habría que escribir sería: `(CACH>=30) & (CACH<=160)` (recordar que los nombres de las variables hay que escribirlos tal cuál están en el conjunto de datos).

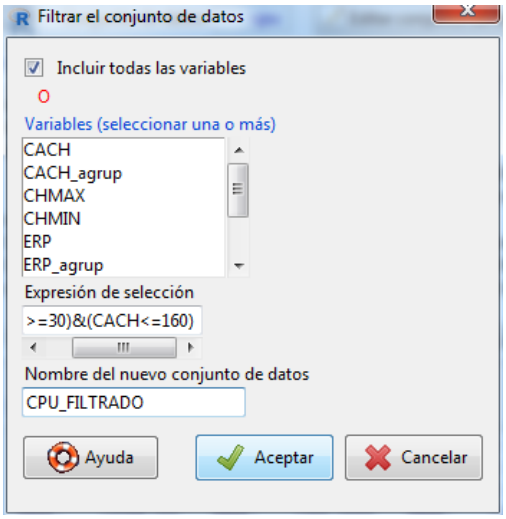


```
CPU_FILTRADO <- subset(cpu, subset=(CACH>=30)&(CACH<=160))
```

Recordatorio: Si pinchamos en el nombre en azul del conjunto de datos activo, se despliega la pestaña con todos los archivos abiertos y generados en esta sesión de R. Podemos pasar de uno a otro sin más que pinchar en el nombre. Recuérdese también que si no se guardan los archivos en el menú visto anteriormente, estos cambios se perderán al cerrar la sesión de R. Por tanto, ya que hemos creado varios conjuntos de datos, sería un buen momento para guardarlos.

Revisar: Los operadores lógicos de R: `help("&")` y las funciones genéricas de R: `help("groupGeneric")`.

7.5 Eliminar niveles de factor sin uso

A veces nos podemos encontrar con variables de tipo factor en los que un determinador valor de la variable no se usa, es decir, no existe ningún sujeto en el conjunto de datos que tome ese valor para la variable. Por ejemplo, al realizar el filtrado anterior sobre el conjunto de datos `cpu`, se han eliminado todos los sujetos que tomaban un determinado valor de alguna de las variables (*Estadística Básica/Estadística Descritiva/ Conjunto de datos activo*):

```
##  ERP_agrup      CACH_agrup
##  BAJA : 0   (-Inf,12]: 0
##  MEDIA:11   (12,32]  :27
##  ALTA :53   (32,65]  :24
##             (65,160] :13
##             (160,256]: 0
```

Este hecho puede afectar bastante a determinadas técnicas estadísticas e incluso llegar a conseguir que no funcionen. Por eso es muy importante descartar estos niveles sin uso. En RCommander podemos realizarlo en el menú *Estadística Básica/Datos/ Modificar Variables del Conjunto de Datos Activo/Descartar niveles sin uso...*:

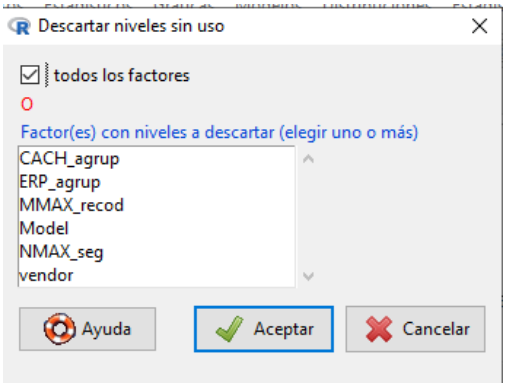


```
CPU_FILTRADO <- droplevels(CPU_FILTRADO)
```

Y ahora las variables tomarían los valores:

```
##  ERP_agrup     CACH_agrup
##  MEDIA:11   (12,32] :27
##  ALTA :53   (32,65] :24
##             (65,160]:13
```

7.6 Recodificar una variable

El RCommander permite recodificar una variable introducciéndo nuevos valores y renombrándola. Supongamos que queremos recodificar la variable MMAX del siguiente modo:

- valores menores o iguales a 10000 como `bajo`
- mayores de 10000 y menores o iguales a 50000 como `medio`
- el resto como `alto`.

El siguiente gráfico indica cómo rellenar el cuadro de diálogo disponible en el menú de *Estadística Básica/Datos/ Modificar Variables del Conjunto de Datos Activo/Recodificar Variables*. Obsérvese que el significado especial de las siguientes variables:

- `lo` representa el valor más **bajo** que toma la variable en el conjunto de datos,
- `hi` representa el valor más **alto** que toma la variable en el conjunto de datos,
- `else` representa a todos los valores que no verifican el resto de condiciones (incluidos los valores `NA`, si correspondiese).

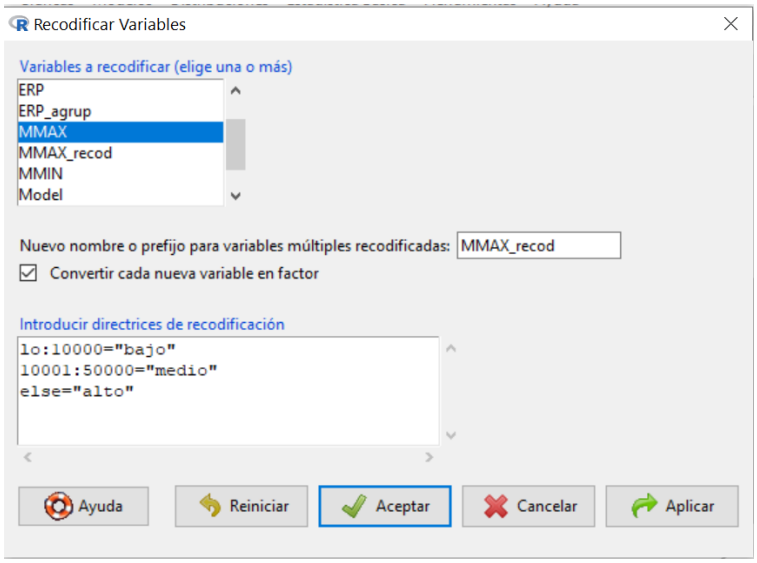


```
cpu <- within(cpu, {
  MMAX_recod <- Recode(MMAX, 'lo:10000="bajo"; 10000:50000="medio"; else="alto"',
  as.factor=TRUE)
})
```

Chequear en el conjunto de datos que ha generado la nueva variable recodificada. Además, en este caso, la variable generada es de tipo ordinal y por tanto habría que comprobar que los niveles de esa variable están ordenados:

```
##  MMAX_recod
##  alto :  4
##  bajo :129
##  medio: 76
```

Como podemos observar, en este caso no están bien ordenados los niveles. Por tanto habría que ordenarlos en el menú anteriormente comentado:

```
cpu <- within(cpu, {
  MMAX_recod <- factor(MMAX_recod, levels=c('bajo','medio','alto'), ordered=TRUE)
})
```

```
##  MMAX_recod
##  bajo :129
##  medio: 76
##  alto :  4
```

NOTA: La recodificación de intervalos es usando intervalos cerrados, es decir, `10000:50000`$=[10000, 50000]$. En el proceso el menú de recodificar va por orden usando intervalos cerrados, por ejemplo, si primero hace `lo:10000`, está considerando $[lo, 10000]$, la siguiente directriz `10000:50000` se corresponde con $[10000, 50000]$ pero como no quedan valores 10000, esta instrucción es equivalente a $(10000, 50000]$.

7.7 Segmentar una variable numérica

Relacionado con recodificar variables existe un procedimiento para segmentar variables numéricas utilizando alguna técnica adecuada para establecer los puntos de corte. Esto se realiza en el menú *Estadística Básica/Datos/Modificar Variables del Conjunto de Datos Activo/Segmentar variable numérica...*. En este menú te permite seleccionar el número de intervalos, establecer nombres, números, rangos o puntos medios del rango a las categorías. También tiene varios métodos de segmentación: equidistantes, de igual cantidad de datos o mediante el algoritmo de agrupación de k-medias.

Como ejemplo, trabajaremos con la variable ERP, la vamos a segmentar esta vez en 3 intervalos equidistantes (de igual longitud) y le asignaremos como nombres de los niveles, el rango al que pertenecen. De esta manera se sabrán los puntos de corte que se han utilizado.

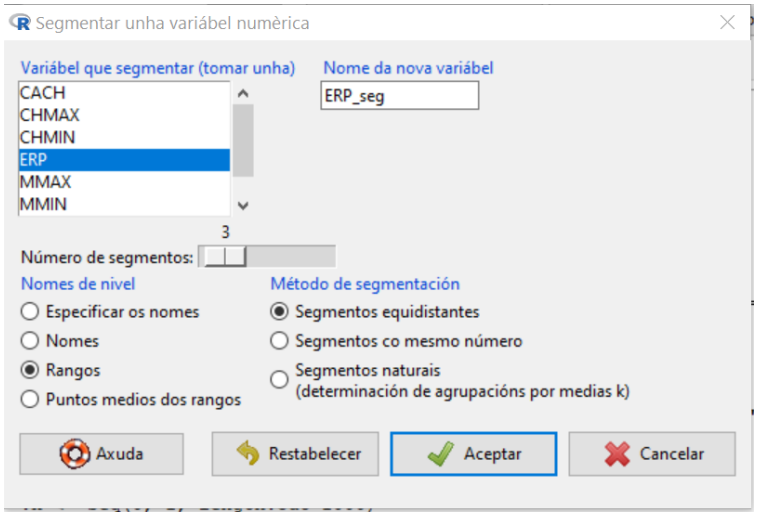


```
cpu$ERP_seg <- as.ordered(with(cpu, binVariable(ERP, bins=3, method='intervals',
                                                labels=NULL)))
```

```
##              ERP_seg
##   (13.8,423]     :203
##   (423,830]      :  3
##   (830,1.24e+03]:  3
```

Al realizar una segmentación, la variable generada es de tipo ordinal y por lo tanto habrá que comprobar que los niveles de las nuevas variables están ordenados. Como podemos observar anteriormente, en este caso ya está ordenada.

Comparemos ahora la segmentación anterior con la segmentación por intervalos de igual cantidad de valores:

```
cpu$ERP_seg2 <- as.ordered(with(cpu, binVariable(ERP, bins=3, method='proportions',
                                                labels=NULL)))
```

```
##             ERP_seg2
##   [15,31]       :71
##   (31,74]       :69
##   (74,1.24e+03]:69
```

7.8 Calcular una nueva variable.

R Commander permite calcular una nueva variable a partir de otra u otras del archivo escribiendo el código directamente en la ventana de script o mediante el menú de *Estadística Básica/Datos/ Modificar Variables del Conjunto de Datos Activo/Calcular una nueva variable...*. Vamos a calcular la diferencia entre MMAX y MMIN. Notar que no es necesario escribir los nombres de las variables que se quieran utilizar en la operación, simplemente haciendo doble click sobre ellas ya se traslada su nombre al cuadro de texto donde haya que escribir la expresión a calcular.

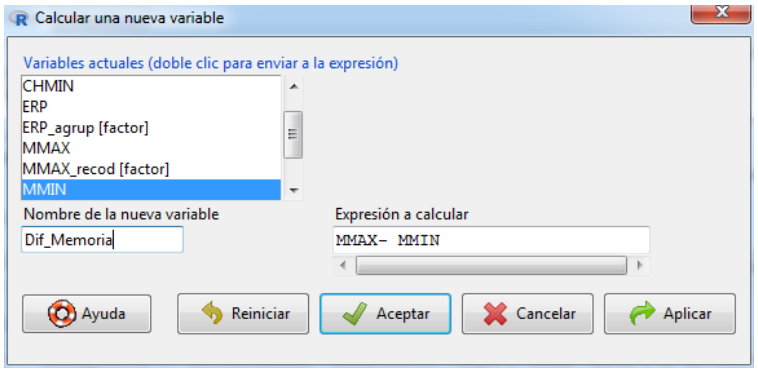


```
cpu$Dif_Memoria <- with(cpu, MMAX- MMIN)
```

Por defecto, para nombrar una variable *en el script* es encesario poner el nombre del archivo y el símbolo `\$`, por ejemplo `cpu$MMAX`. Si no queremos poner el nombre del archivo y referirnos a la varible solamente, es encesario utilizar la función `attach` con el nombre del conjunto de datos, es decir, `attach(cpu)`. A partir de ahí el software reconoce que MMAX es la variable correspondiente al conjunto de datos cpu. Otra opción sería trabajar con la función `with`, como en la línea de comandos anterior.

8 Actividades

1. Obtener de la página web del IGE (http://www.ige.eu) los datos de población del año 2018 de cualquier municipio que os interese de la mima forma que se hizo en la sección 5.2.4.
   a. Importar los datos a R.
   b. Eliminar todas las variables salvo `Grupos.de.idade`, `Espazo` y `DatoN`.
   c. Clasificar las variables y convertir al formato de R adecuado aquellas variables que sea necesario. Recuerda reordenar los niveles de factor de aquellas variables que lo necesiten.
2. Abre el archivo de datos `airquality` del paquete `datasets`. Estos datos indican los datos de Ozono, Temperatura, radiación solar y Velocidad del viento de varios días en una estación meteorológica.
   a. Lee la ayuda que proporciona R para el conjunto de datos (`help(airquality)`) y clasifica todas las variables estadísticas que tiene el conjunto de datos.
   b. La variable `Month` que representa el mes de la medición, está considerada como numérica, aunque en realidad es una variable cualitativa. Transforma la variable `Month` a varible factor de tipo ordinal.
   c. Ordena el conjunto de datos de manera decreciente en función de la variable `Ozone`.
   d. Recodifica la variable `Month` con los nombres de los meses correspondientes y guarda la nueva variable como `Month_text`. Ordena los niveles si fuese necesario.
   e. Recodifica la variable `Ozone` en los siguientes intervalos: [0,50], (50,100] y (100,170] y guardala como `Ozone_cat`. (Cuidado con los valores `NA`). Ordena los niveles si fuese necesario.
   f. Segmenta la variable `Wind` en 4 segmentos de igual longitud (equidistantes). Utiliza los rangos como nombres de los niveles y guarda la nueva variable como `Wind_seg1`. Ordena los niveles si fuese necesario.
   g. Segmenta la variable `Wind` en 4 segmentos de igual cantidad. Utiliza los rangos como nombres de los niveles y guarad la nueva variable como `Wind_seg2`. Ordena los niveles si fuese necesario.
   h. Realiza un resumen numérico básico y compara las variables `Wind_seg1` y `Wind_seg2`.

i. La variable `Wind` está medida en *millas/h*, crear una nueva variable `Wind_kmh` que mida la velocidad en *km/h* (el factor de conversión es `1.609344`).

j. La variable `Temp` está representada en grados Fahrenheit. Hacer la conversión a grados Celsius en una nueva variable `Temp_C` (utilizar la fórmula de conversión: $C = (F - 32) \cdot \frac{5}{9}$).

k. Crear un nuevo conjunto de datos donde la temperatura sea superior a 25 ºC y el nivel de ozono inferior a 65 ppm. (utilizar el menú de filtrar).

3. Abre el archivo `Ocupaciones.csv` utilizando un editor de texto plano. En él aparecen una lista de personas con algunos datos característicos:

   - `edad`: Edad en años,
   - `estudios`: Nivel de estudios alcanzado, siendo
     - `1`: Primarios
     - `2`: Secundarios
     - `3`: Superiores
   - `ocupacion`: Sector de ocupación, siendo
     - `1`: Parado, jubilado o estudiante
     - `2`: Servicios
     - `3`: Construccion
     - `4`: Industria
   - `peso`: Peso en Kg
   - `altura`: Altura en m
   - `edad_r`: Edad recodificada en 3 rangos: 0-16, 17-65 y Más de 65.

   Con este conjunto de datos realiza las siguientes tareas:

   a. Importar el conjunto de datos y clasifica todas las variables estadisticas que tiene.

   b. Convierte cada variable al tipo de R adecuado.

   c. Recodifica las variables `estudios` y `ocupacion` según los valores que se indican arriba. Recuerda clasificar bien las nuevas variables y reordenar los niveles de los factores si fuese necesario.

   d. Comprueba si existe algún error de introducción de datos en la variable `altura` y corrígelo.

   e. La variable 'edad_r' contiene algún error de codificación. Para localizarlo, recodifica de nuevo la variable `edad` en los mismos rangos. Intenta localizar donde están los errores. (PISTA: Nos puede ayudar realizar una tabla de contingencia en el menú *Estadística Básica/Estadística Descriptiva/Tabla de contingencia/Tabla de doble entrada...* y para localizar los errores podríamos filtrar el conjunto de datos)

   f. Calcula una nueva variable que nos proporcione el índice de masa corporal (IMC) y guárdala con el nombre `IMC` (recordar que $IMC = \frac{\text{peso en kg}}{(\text{altura en m})^2}$).

   g. Segmenta las variables `peso` y `altura` en 3 partes de igual cantidad. Ordena los niveles si fuese necesario.

   h. Crea un nuevo conjunto de datos con todas las personas que no son paradas, jubiladas o estudiantes y llámalo `ocupaciones_activos` (en R `!=` significa distinto). Comprueba si existen niveles de factores sin uso y descártalos.